Отчёт по практическому циклу

«Доверенность и безопасность систем искусственного интеллекта»

Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки

Базовый проект: minanabil96/mina_covid-xray-detector · чекпоинт best_model.pth (заморожен, без переобучения) · ПР1–ПР4 · seed = 42 · уровень доверия 95%

Авторы: Панов А. Ю., Семенов М. Д., Ханна М. Н. — группа 1378

Краткое резюме

Проведён полный аудит доверенности замороженной модели-классификатора COVID/Normal по рентгенограммам (ResNet18 с предобученным backbone, дообучен только блок layer4 и классификационная голова). Модель имеет высокую точность на чистом тесте M(0) = 0.9833 (95% ДИ 0.9711; 0.9904), точно воспроизводимую по базовому эксперименту. Аудит выявил системные риски доверенности.

- **Сдвига нет.** Данные в целом сбалансированы и репрезентативны: распределения train и test не различаются (MMD^2 = -0.00039, p = 0.705; C2ST AUC = 0.4885 [0.4640; 0.5139]).
- **Качество данных.** Обнаружены дубликаты и файловая утечка: 0,64% точных и 3,64% пиксельно подтверждённых близких дубликатов; между train и test — 7 точных и 64 близких пар снимков. Лейбл-шум мал (train 0/5760, test 3/720).
- **Коррупции (ПР2).** Модель катастрофически чувствительна к шуму: статистически значимое падение начинается уже с сублиминального уровня (гауссов шум sigma = 0,005), а при sigma >= 0,02 происходит полный коллапс предсказаний (точность ~0,50). К JPEG и размытию модель существенно устойчивее.
- **Состязательные атаки (ПР3).** Модель не обладает состязательной устойчивостью: PGD-10 при eps = 1/255 обращает в неверные 100% чисто-правильных предсказаний (FR = 1,000); Validity Rate всех adversarial-примеров = 1,000. FGSM при eps = 1/255 даёт FR = 0,558.
- **Приватность (ПР4).** Обнаружен слабый, пограничный сигнал членства (MIA): ROC-AUC = 0.5561 [0.5060; 0.6072]; Attack Accuracy = 0.5460 [0.5022; 0.5891] (Wilson). Процентильные интервалы loss и confidence не накрывают 0,5, но BCa-интервал loss отстоит от 0,5 лишь на 0,0017, а BCa для entropy [0,4976; 0,6021] включает 0,5; нижняя граница Attack Accuracy выше 0,5 лишь на 0,0022. TPR@FPR ≤ 1% практически нулевой. Генерализационный разрыв 2,8 п.п. — поддерживающее, а не решающее свидетельство.

Итог: система применима как исследовательский прототип с высокой точностью на «идеальных» снимках, но в исследованных условиях не готова к клиническому применению без (а) входного контроля качества изображений, (б) состязательного дообучения и (в) устранения утечек при построении сплитов.

1. Описание предметной области и аналитической задачи

Предметная область — компьютерная диагностика по медицинским изображениям (компьютерное зрение в здравоохранении). Аналитическая задача — бинарная классификация фронтальных рентгенограмм грудной клетки по признаку COVID-19 («COVID» против «Normal») по единственному входному снимку. Контекст применения: система поддержки принятия врачебных решений в условиях скрининга/сортировки; итоговое решение остаётся за клиницистом, а модель выступает triage-помощником.

Почему важна доверенность: задача критическая по последствиям ошибок. Ложноотрицательный результат (COVID → Normal) ведёт к пропуску инфекции и задержке лечения; ложноположительный (Normal → COVID) — к необоснованным изоляции и дообследованию. Модель должна быть проверена не только на «идеальных» снимках, но и на устойчивость к искажениям, к целенаправленным (состязательным) воздействиям и на приватность обучающих данных — именно этому посвящён цикл ПР1–ПР4.

Выводы отчёта носят условный характер: они ограничены выбранными данными, классами искажений, моделью нарушителя и статистической неопределённостью (см. раздел 8 и раздел 9).

2. Описание набора данных и глубокой модели

Модель. ResNet18 (torchvision), предобученный на ImageNet; при обучении заморожены все слои, кроме layer4 и головы fc = Dropout(0,5) + Linear(512, 2). Классы: COVID = 0, Normal = 1 (порядок ImageFolder по алфавиту). Оценочные преобразования: Resize(224,224) -> ToTensor -> Normalize(ImageNet mean/std). Класс COVID соответствует целевой положительной метке.

Данные. Набор COVID-19 Radiography Database (v4), используемый в Covid_detector.ipynb; для воспроизведения применён идентичный по составу файлов зеркальный источник (junelsolis/covid-19-radiography-dataset). Организовано по 3600 отсортированных файлов каждого класса (COVID, Normal), всего 7200 снимков; сплит 80/10/10 (5760/720/720) с seed 42, воспроизводится бит-в-бит относительно исходного ноутбука.

3. Baseline-качество модели и 95%-й доверительный интервал

На неизменённом тестовом наборе (n = 720: COVID 361 / Normal 359) получено точное совпадение с training_history.json: TP = 354, FN = 7, FP = 5, TN = 354.

Метрика	Значение	95% ДИ	Метод
Accuracy	0.9833	[0.9711; 0.9904]	Wilson
Recall (COVID)	0.9806	[0.9605; 0.9906]	Wilson
Precision (COVID)	0.9861	[0.9678; 0.9940]	Wilson
F1 (COVID)	0.9833	[0.9727; 0.9918]	bootstrap, B=2000

M(0) = 0.9833 (0.9711; 0.9904) — точное воспроизведение базовой метрики подтверждает корректность пайплайна и разбиения (results/baseline_eval.json).

4. Профиль качества данных — результаты ПР1

Проведён аудит 7200 снимков: читаемость файлов, размеры и модальность, статистика яркости/контраста/резкости, дубликаты (MD5 и перцептивный хеш), утечки между сплитами, качество меток (confident learning на out-of-sample вероятностях линейной головы), распределительный сдвиг (MMD и C2ST), а также метрики качества изображений NIQE/BRISQUE и детекция рамок/размытия.

Сводный профиль (полная таблица — results/pr1_quality_profile.csv):

Свойство	Метрика	Значение	95% ДИ
Completeness	доля нечитаемых/повреждённых файлов	0.0000	[0.0000; 0.0005]
Validity	доля grayscale-файлов (режим L)	1.0000	[0.9995; 1.0000]
Validity	доля файлов с min стороной < 128 px	0.0000	[0.0000; 0.0005]
Uniqueness	доля точных дубликатов (MD5)	0.0064	[0.0048; 0.0085]
Uniqueness	доля близких дубликатов (пиксельно подтвержд.)	0.0364	[0.0323; 0.0410]
Uniqueness	структурно схожие пары phash<=6 (шт., точная характеристика)	1930.0000	—
Uniqueness	доля структурно схожих пар phash<=6 (от 7200)	0.2681	[0.2579; 0.2784]
Leakage	точные пары train<->test (шт., точная характеристика)	7.0000	—
Leakage	доля точных пар train<->test (от |train|)	0.0012	[0.0006; 0.0025]
Leakage	близкие пары train<->test (пиксельные, шт., точная характеристика)	64.0000	—
Leakage	доля близких пар train<->test (от |train|)	0.0111	[0.0087; 0.0142]
Balance	соотношение классов Normal/COVID (test)	0.9945	—
Balance	классовая энтропия (test, биты)	0.6931	—
Label quality	подозрительные метки train (доля)	0.0000	[0.0000; 0.0007]
Label quality	подозрительные метки test (доля)	0.0042	[0.0014; 0.0122]
Shift	MMD^2 train<->test (95% перцентили нулевого распределения H0)	-0.0004	[-0.0008; 0.0018]
Shift	C2ST CV-точность	0.5923	[0.5718; 0.6126]
Shift	C2ST CV-AUC	0.4885	[0.4640; 0.5139]
Anomalies	доля снимков NIQE > Q97.5(train)	0.0222	[0.0061; 0.0774]
Anomalies	доля чрезмерно размытых (< Q2.5 лаплас.)	0.0250	[0.0216; 0.0289]
Anomalies	доля снимков с чёрной рамкой (Normal)	0.0069	[0.0047; 0.0102]

Ключевые находки:

- Полнота и валидность идеальны: 0 нечитаемых файлов; 100% grayscale; min-сторона >= 128 px у всех снимков.
- Дубликаты: 46 файлов-дубликатов (0,64%, 34 группы по MD5) и 262 пиксельно подтверждённых близких дубликата (3,64%, 199 кластеров; критерий phash <= 6 и средняя абсолютная разница пикселей <= 10). Отдельно выделены 1930 «структурно похожих» пар (phash <= 6, но визуально различных) — они дубликатами не считаются.

- Утечка train<->test: 7 точных и 64 близких пиксельно подтверждённых пар. Часть тестовых снимков имеет почти идентичного «двойника» в обучении — потенциальный источник завышения тестовой метрики и искажения оценок приватности.
- Качество меток: подозрительных меток на train = 0/5760; на test = 3/720 (0,42% [0.0014; 0.0122]). Выполнен ручной разбор объектов с наименьшим label quality (см. results/pr1_label_inspection.csv): на train кандидаты объясняются атипичностью снимков, а не ошибками меток; на test помечены единичные пограничные случаи.
- Сдвиг отсутствует: MMD^2 = -0.00039 (p = 0.705), C2ST AUC = 0.4885 [0.4640; 0.5139] — тест является IID-подмножеством того же домена.
- Артефакты изображений: доля чрезмерно размытых ~2,5%; снимков с тёмной рамкой ~0,7–0,9%; атипичных по NIQE на test ~2,2%. NIQE: COVID 6,52 [6,31; 6,76] против Normal 5,91 [5,80; 6,02].

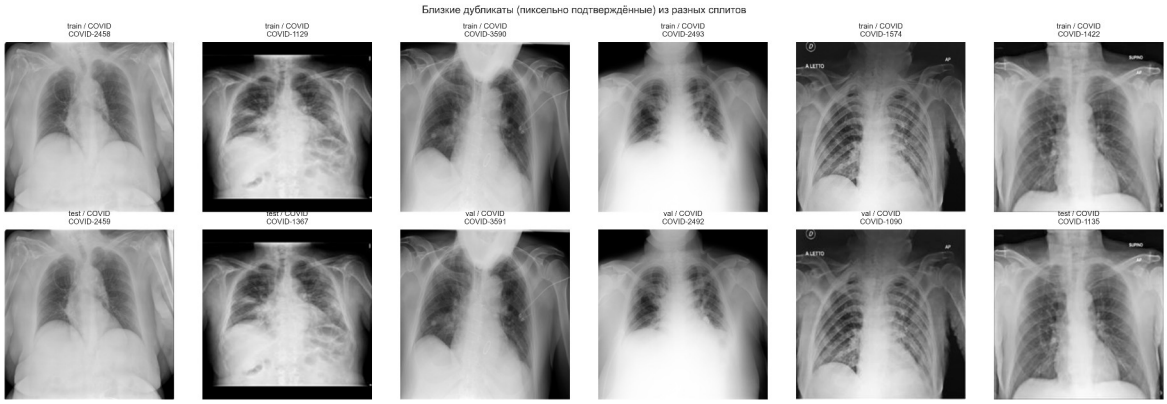


Рис. 1. Примеры близких дубликатов (пиксельно подтверждённых) из разных сплитов — почти идентичные снимки одновременно в train и test.

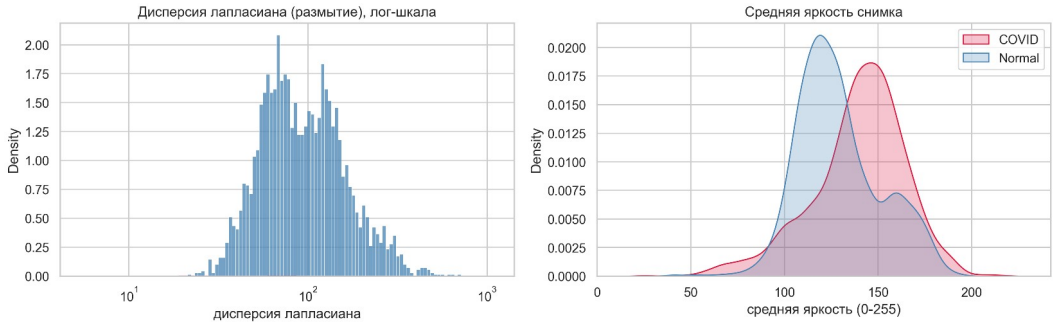


Рис. 2. Распределения яркости и резкости (лапласиан) — визуальный контроль артефактов качества.

5. Устойчивость к естественным искажениям — результаты ПР2

Исследована устойчивость к четырём типам естественных искажений (гауссов и пуассоновский шум, гауссово размытие, JPEG-компрессия) по пяти уровням severity. Для

стохастических искажений использовано 5 независимых реализаций (разные seed); интервалы построены иерархическим bootstrap по объектам (объект × реализация, B=2000), для ΔM применён парный bootstrap (одинаковые индексы объектов на clean и corrupted). Метрики: R(s) — accuracy на испорченном тесте; ΔM(s) = M(0) − R(s); площадная устойчивость R-AUC (трапеции, включая s = 0) с процентильным и BCa-интервалами.

Важное методологическое уточнение: пилотно обнаружено, что модель коллапсирует уже при гауссовом sigma >= 0,02 (примерно 5/255, визуально незаметный шум). Поэтому шумовые шкалы перекалиброваны на сублиминальные уровни (гауссов sigma = 0,005… 0,08; пуассоновский lambda = 2048…128), чтобы кривая R(s) была информативной (задокументированное отклонение).

Таблица устойчивости (R(s) и ΔM(s) по уровням):

Искажение	s	R(s)	95% ДИ R	ΔM(s)	95% ДИ ΔM	значимо
gaussian_blur	1	0.9819	[0.9722; 0.9917]	0.0014	[-0.0083; 0.0111]	нет
gaussian_blur	2	0.9611	[0.9458; 0.9750]	0.0222	[0.0083; 0.0375]	да
gaussian_blur	3	0.7500	[0.7167; 0.7819]	0.2333	[0.2014; 0.2667]	да
gaussian_blur	4	0.5028	[0.4652; 0.5389]	0.4806	[0.4444; 0.5181]	да
gaussian_blur	5	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да
gaussian_noise	1	0.8181	[0.7889; 0.8458]	0.1653	[0.1375; 0.1944]	да
gaussian_noise	2	0.5614	[0.5250; 0.5972]	0.4219	[0.3861; 0.4583]	да
gaussian_noise	3	0.5028	[0.4652; 0.5389]	0.4806	[0.4444; 0.5181]	да
gaussian_noise	4	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да
gaussian_noise	5	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да
jpeg	1	0.9694	[0.9556; 0.9806]	0.0139	[0.0027; 0.0278]	да
jpeg	2	0.8931	[0.8694; 0.9153]	0.0903	[0.0681; 0.1139]	да
jpeg	3	0.8028	[0.7722; 0.8306]	0.1806	[0.1528; 0.2111]	да
jpeg	4	0.6792	[0.6417; 0.7139]	0.3042	[0.2694; 0.3417]	да
jpeg	5	0.5458	[0.5069; 0.5819]	0.4375	[0.4014; 0.4764]	да
poisson_noise	1	0.5472	[0.5083; 0.5820]	0.4361	[0.4014; 0.4750]	да
poisson_noise	2	0.5078	[0.4694; 0.5444]	0.4756	[0.4389; 0.5139]	да
poisson_noise	3	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да
poisson_noise	4	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да
poisson_noise	5	0.5014	[0.4625; 0.5375]	0.4819	[0.4458; 0.5208]	да

Площадная устойчивость R-AUC (процентильный и BCa bootstrap, B=2000):

Искажение	R-AUC	95% ДИ (percentile)	95% ДИ (BCa)	падение на s=5, %
gaussian_noise	0.6252	[0.5958; 0.6527]	[0.5959; 0.6515]	49.0%
poisson_noise	0.5600	[0.5266; 0.5913]	[0.5269; 0.5920]	49.0%
gaussian_blur	0.7876	[0.7699; 0.8036]	[0.7698; 0.8039]	49.0%
jpeg	0.8218	[0.8017; 0.8404]	[0.8012; 0.8381]	44.5%

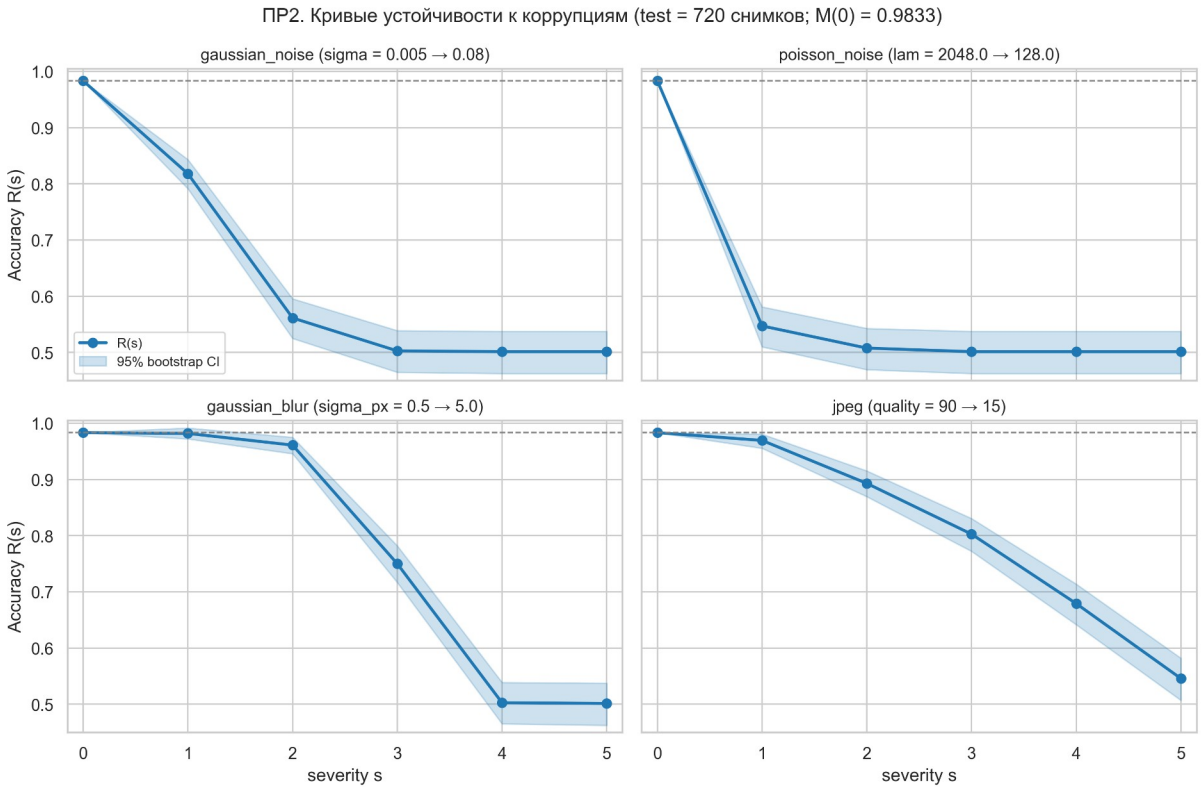


Рис. 3. Кривые устойчивости R(s) с 95% доверительными полосами (включая точку s = 0 = M(0)).

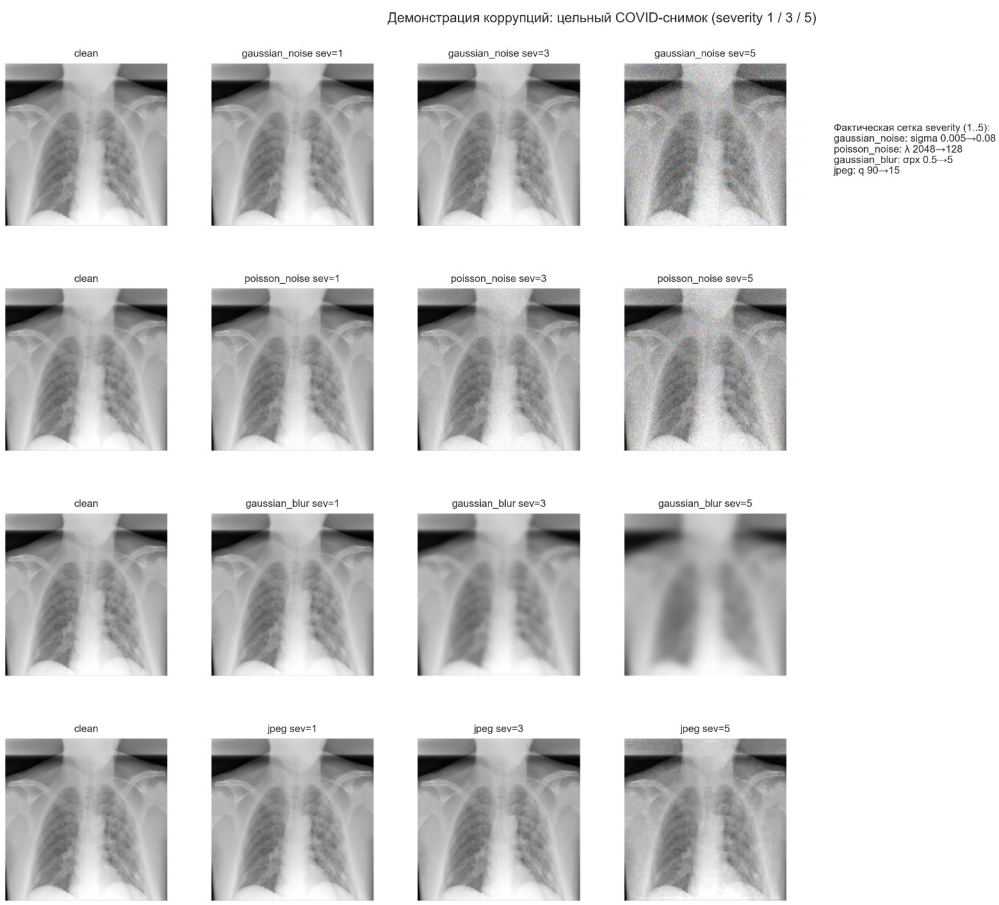


Рис. 4. Демонстрация искажений (severity 1/3/5) для одного COVID-снимка; указана фактическая сетка severity.

Выводы ПР2:

- Наиболее устойчива модель к JPEG (R-AUC = 0,822) и умеренно — к размытию (R-AUC = 0,788). К шуму обоих типов — крайне низкая устойчивость (R-AUC 0,625 для гауссова и 0,560 для пуассоновского).
- Статистически значимое падение точности наступает уже на минимальных уровнях: гауссов шум sigma = 0,005 (0,983 -> 0,818), пуассоновский шум lambda = 2048 (-> 0,547), JPEG q = 90 (-> 0,969), размытие sigma_px = 1,0 (-> 0,961).
- Полный коллапс (точность на уровне случайной ~0,50) наступает при sigma >= 0,02, lambda <= 2048, размытии sigma_px >= 3,5 и JPEG q = 15.
- Практический смысл: модель опирается на тонкую высокочастотную структуру и не пригодна для снимков с шумом; необходим входной контроль качества (детекция шума/размытия) до инференса.

6. Adversarial robustness — результаты ПР3

Модель нарушителя (зафиксирована до эксперимента, §4.2): knowledge = white-box; goal = untargeted; access = градиенты; perturbation space = L∞ по пикселям [0,1]; attack budget ε ∈ {1,2,4,8,16}/255 (query budget и число изменённых пикселей — N/A для white-box); validity constraint — клип [0,1]. Атаки: FGSM и PGD-10 (alpha = ε/4, случайный старт, 3 перезапуска, best-of-loss) на стратифицированном подмножестве из 200 тестовых снимков (100 COVID + 100 Normal; M_sub(0) = 0,9850 [0,9568; 0,9949]; 197 чисто-правильных). Для стохастической части PGD выполнена серия из 3 seeds при ε = 8/255. Независимая проверка — APGD-CE (ε = 8/255, n = 20); это не полный AutoAttack.

Результаты атак (FR = ASR: доля чисто-правильных, ставших неверными; robust_acc — точность на состязательном наборе; Validity Rate — доля доменно допустимых примеров):

Метод	ε	FR (ASR)	95% ДИ FR	robust_acc	95% ДИ RA	Validity Rate
FGSM	1/255	0.5584	[0.4886; 0.6259]	0.4350	[0.3682; 0.5043]	1.0000
FGSM	2/255	0.5025	[0.4333; 0.5716]	0.5000	[0.4314; 0.5686]	1.0000
FGSM	4/255	0.5025	[0.4333; 0.5716]	0.5000	[0.4314; 0.5686]	1.0000
FGSM	8/255	0.5025	[0.4333; 0.5716]	0.5000	[0.4314; 0.5686]	1.0000
FGSM	16/255	0.5025	[0.4333; 0.5716]	0.5000	[0.4314; 0.5686]	1.0000
PGD10	1/255	1.0000	[0.9809; 1.0000]	0.0000	[0.0000; 0.0188]	1.0000
PGD10	2/255	1.0000	[0.9809; 1.0000]	0.0000	[0.0000; 0.0188]	1.0000
PGD10	4/255	1.0000	[0.9809; 1.0000]	0.0000	[0.0000; 0.0188]	1.0000
PGD10	8/255	1.0000	[0.9809; 1.0000]	0.0000	[0.0000; 0.0188]	1.0000
PGD10	16/255	0.9949	[0.9718; 0.9991]	0.0050	[0.0009; 0.0278]	1.0000

Величина возмущений (δ = x_adv − x_clean; L∞ ограничен бюджетом, L_2 приведён как статистика):

Метод	ε	mean $\|\|\delta\|\|_2$	max $\|\|\delta\|\|_2$	max $\|\|\delta\|\|_\infty$	бюджет ε (доля)
FGSM	1/255	1.5091	1.5215	0.00392	0.00392
FGSM	2/255	3.0155	3.0430	0.00784	0.00784
FGSM	4/255	6.0221	6.0860	0.01569	0.01569
FGSM	8/255	12.0099	12.1719	0.03137	0.03137
FGSM	16/255	23.9090	24.3438	0.06275	0.06275
PGD10	1/255	1.0133	1.0303	0.00392	0.00392
PGD10	2/255	1.9864	2.0202	0.00784	0.00784
PGD10	4/255	3.9315	3.9768	0.01569	0.01569
PGD10	8/255	7.8171	7.9193	0.03137	0.03137
PGD10	16/255	15.5422	15.7816	0.06275	0.06275

Мульти-seed серия PGD при ε = 8/255 (проверка устойчивости к seed):

seed	FR (ASR)	95% ДИ FR	robust_acc
42	1.0000	[0.9809; 1.0000]	0.0000
43	1.0000	[0.9809; 1.0000]	0.0000
44	1.0000	[0.9809; 1.0000]	0.0000

Площадная устойчивость R-AUC_ε (нормированная площадь под кривой robust-accuracy):

Метод	R-AUC_ε	95% ДИ
FGSM	0.5111	[0.4497; 0.5798]
PGD10	0.0320	[0.0303; 0.0348]

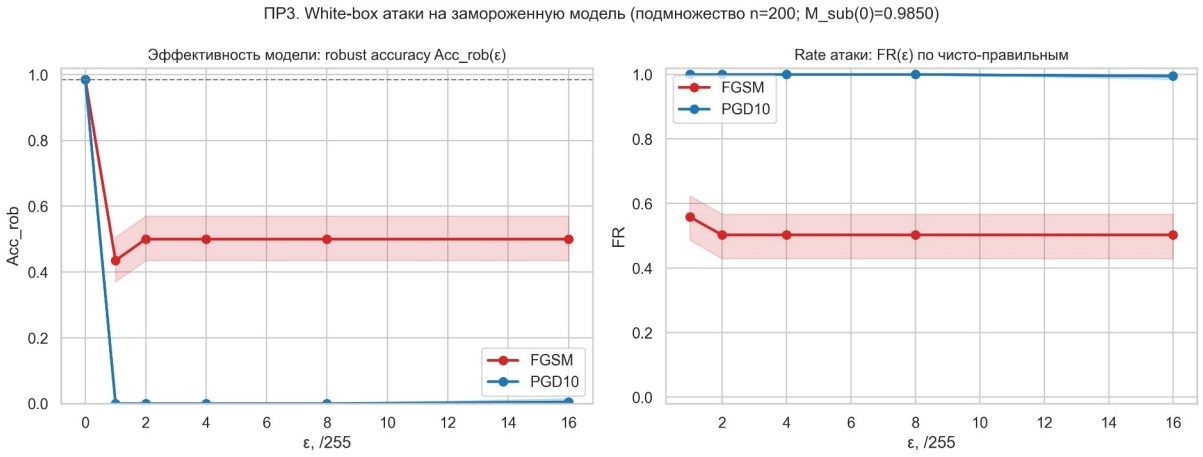


Рис. 5. Состязательная устойчивость: точность на состязательном наборе и частота успеха атак (FR) по бюджету eps.

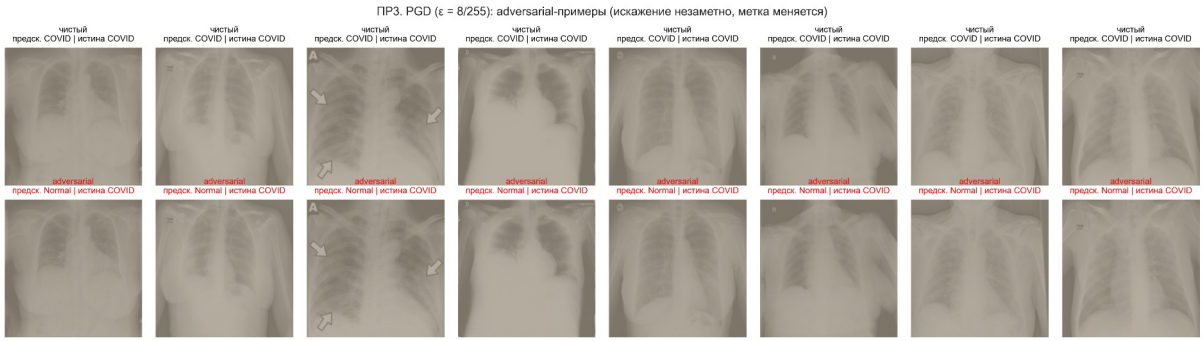


Рис. 6. Примеры состязательных возмущений (PGD, eps = 8/255): искажения визуально незаметны, предсказание меняется на противоположное.

Выводы ПР3:

- PGD-10 обращает в неверные 197/197 чисто-правильных предсказаний уже при eps = 1/255 (FR = 1,000), то есть robust-accuracy падает до 0 в пределах визуально незаметного возмущения.

- FGSM существенно слабее (FR = 0,558 при eps = 1/255) и при больших eps насыщается около FR ≈ 0,50 из-за смещения всех предсказаний в один класс.
- Validity Rate = 1,000 для всех пар (атака, ε): все примеры конечны и лежат в [0,1]; max ||δ||∞ не превышает бюджет. Серия 3 seeds при ε = 8/255 даёт FR = 1,000; 1,000; 1,000 — результат устойчив к seed.
- Независимый чекер APGD-CE (ε = 8/255, n = 20) даёт FR = 1.000 [0.8389; 1.0000] и robust_acc = 0.0000; это согласуется с PGD-10 на данном подмножестве и не выявляет признаков gradient masking, но не доказывает их отсутствие (n = 20, только APGD-CE).
- Протокол — untargeted, поэтому направление ошибки и доля переходов COVID → Normal количественно не измеряются. Для клинического применения переход COVID → Normal (пропуск диагноза) остаётся наиболее критичным сценарием, но его частота в этом эксперименте не оценена. Состязательное дообучение не выполнялось (модель заморожена по заданию) и является первоочередной рекомендацией.

Ограничения ПР3 (задокументированы): независимый чекер ограничен APGD-CE на n = 20; это не полный AutoAttack. Компоненты APGD-T/FAB-T и DLR-лоссы в работе не использовались; полная композиция AutoAttack для двухклассовой задачи не запускалась. Реализация torchattacks APGD утекает память VRAM на каждый вызов, что при 4 ГБ GPU допускает лишь один вызов на подмножестве из 20 снимков. Это ограничивает полноту проверки, но не меняет качественный вывод в рамках исследованного протокола.

7. Privacy leakage — результаты ПР4

Проверено, может ли атакующий с чёрным ящиком определить, входил ли снимок в обучающую выборку. Единица приватности — отдельный снимок (image-level): метаданные набора не содержат идентификаторов пациентов (проверено: data/COVID.metadata.xlsx и Normal.metadata.xlsx содержат только FILE NAME/FORMAT/SIZE/URL). Протокол: 250 членов и 250 не-членов для калибровки порога и 250 + 250 для независимой оценки; выборки стратифицированы по классам. Атака — loss-threshold: порог τ* подбирался на attack-validation (balanced accuracy) и на attack-test не переоптимизировался; оценка — на независимой attack-test половине.

Основная практическая метрика — Attack Accuracy (доля правильных membership-решений при τ*):

Attack Accuracy (loss-атака) = 0.5460 [Wilson 95% CI: 0.5022; 0.5891], матрица решений TP=177, FN=73, FP=154, TN=96. Вспомогательно: Balanced Accuracy = 0.5460 [bootstrap CI: 0.5060; 0.5880].

Полная таблица MIA (ROC-AUC — стратифицированный percentile- и BCa-bootstrap; TPR@FPR — стратифицированный bootstrap с пересчётом ROC; B=2000):

Атака	ROC-AUC	95% ДИ (percentile)	95% ДИ (BCa)	Attack Acc	95% ДИ (Wilson)	BA (eval)	TPR@FPR=1% [CI]	TPR@FPR=0,1% [CI]
loss	0.5561	[0.5060; 0.6072]	[0.5017; 0.6044]	0.5460	[0.5022; 0.5891]	0.5460	0.0000 [0.0000; 0.0000]	0.0000 [0.0000; 0.0000]
confidence	0.5559	[0.5058; 0.6070]	[0.5014; 0.6042]	0.5460	[0.5022; 0.5891]	0.5460	0.0000 [0.0000; 0.0000]	0.0000 [0.0000; 0.0000]
entropy	0.5536	[0.5008; 0.6051]	[0.4976; 0.6021]	0.5460	[0.5022; 0.5891]	0.5460	0.0040 [0.0000; 0.0440]	0.0040 [0.0000; 0.0160]

Генерализационный разрыв (поддерживающее свидетельство): точность на членах 1.0000 [0.9849; 1.0000] против не-членов 0.9720 [0.9433; 0.9864] (разрыв 0.0280). Средние: loss 0.0014 против 0.0643; уверенность 0.9986 против 0.9880.

Интерпретация интервалов. Процентильные 95%-интервалы ROC-AUC для loss и confidence не накрывают 0,5, однако BCa-интервал loss отстоит от 0,5 лишь на 0,0017, а BCa-интервал entropy [0,4976; 0,6021] включает 0,5; нижняя граница Wilson-интервала Attack Accuracy (0,5022) выше 0,5 лишь на 0,0022. Поэтому сигнал следует описывать как слабый и пограничный, а не как сильную или доказанную утечку. Loss, confidence и entropy — монотонные функции одних и тех же выходов модели: это не три независимых свидетельства, а три представления одного и того же сигнала.

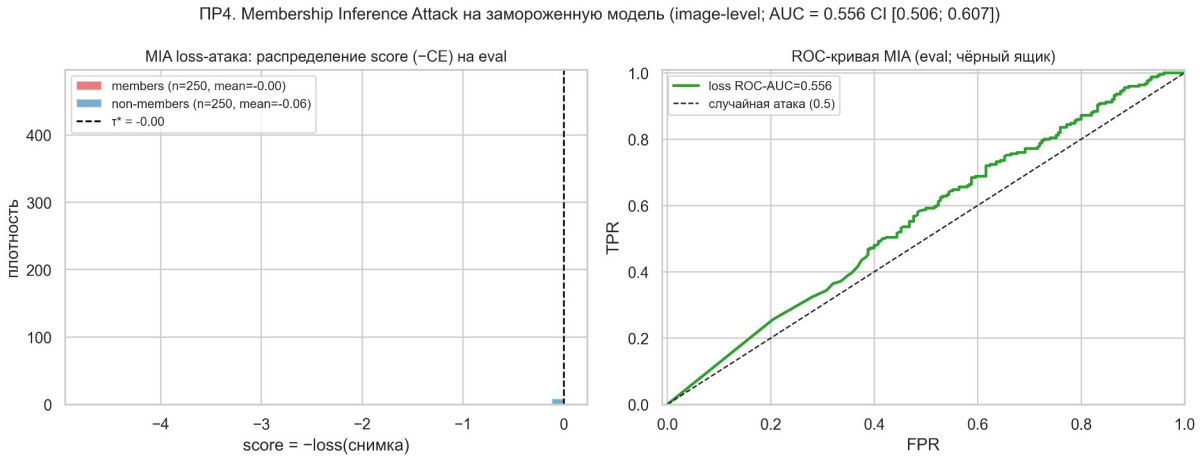


Рис. 7. MIA: распределения функции потерь для членов и не-членов (слева) и ROC-кривая атаки (справа).

Выводы ПР4:

- Обнаружен слабый, пограничный сигнал членства: ROC-AUC ≈ 0.5561 [0.5060; 0.6072], Attack Accuracy = 0.5460 [Wilson 0.5022; 0.5891]. Процентильные интервалы loss и confidence не накрывают 0,5, но BCa-интервал loss отстоит от 0,5 лишь на 0,0017, а BCa для entropy [0,4976; 0,6021] включает 0,5; нижняя граница Attack Accuracy выше 0,5 лишь на 0,0022. Это не свидетельство сильной утечки и не доказательство приватности.

- При практически значимых низких FPR атака почти бесполезна: TPR@FPR = 1% равен 0,000 для loss и confidence; у entropy — 0,004 [0,000; 0,044]. TPR@FPR = 0,1% также практически нулевой.
- Генерализационный разрыв 2,8 п.п. (accuracy членов 1,0000 [0,9849; 1,0000] против не-членов 0,9720 [0,9433; 0,9864]; средние loss 0,0014 против 0,0643) согласуется с запоминанием, но не доказывает практически используемую утечку: интервал для разности не строился, а сам разрыв мал относительно неопределённости на 250 объектах. Это поддерживающее, а не решающее свидетельство.
- Loss, confidence и entropy — монотонные преобразования одних и тех же выходов; совпадение их AUC не является независимым подтверждением. Ограничения: единица приватности — image-level; patient IDs отсутствуют; дубликаты train↔test могут как усиливать, так и ослаблять сигнал, направление суммарного эффекта не измерено; глубокие атаки (shadow models, LiRA) не реализованы.

8. Обобщение полученных экспериментальных свидетельств

Сводная картина доверенности замороженной модели в рамках исследованного протокола:

Данные пригодны для базового исследования: сбалансированы, без сдвига train/test, с малым лейбл-шумом; однако присутствуют точные/близкие дубликаты и файловая утечка train↔test (7 точных + 64 близких пар), что ограничивает силу выводов о генерализации и приватности. Модель показала высокую точность на чистом тесте (M(0) = 0,9833), но крайне низкую устойчивость к шуму (значимое падение уже при σ=0,005) и отсутствие состязательной устойчивости в исследованном бюджете (FR = 1,000 при ε=1/255 при Validity Rate = 1,000). Приватность: слабый, пограничный сигнал членства (ROC-AUC ≈ 0,556; Attack Accuracy 0,546), практически незначимый при низких FPR; BCa-интервал loss отстоит от 0,5 лишь на 0,0017, а BCa для entropy включает 0,5. Все оценки сопровождаются 95%-ми интервалами, а выводы ограничены выбранными данными, классами искажений, моделью нарушителя и статистической неопределённостью.

Сводная таблица результатов (§6.2 методики):

Свойство	Эксперимент	Основная метрика	Результат	95% CI	Вывод
Data quality	ПР1	label error / shift / duplicates / leakage	label err. test 3/720; MMD p=0.705; близких дубл. 3,64%; утечка 7 точных + 64 близких пар	C2ST AUC [0.4640; 0.5139]	Данные пригодны для базового аудита (сдвига нет, лейбл-шум мал), но дубликаты и файловая утечка train↔test ограничивают обобщаемость и могут слегка завышать тестовую метрику.
Corruption robustness	ПР2	R-AUC	JPEG 0,822; blur 0,788; гауссов шум 0,625; пуассоновский 0,560	[0,8208;0,8226] / [0,7867;0,7885] / [0,6242;0,6260] / [0,5591;0,5609] (percentile); BCa в §5	В исследованных условиях модель неустойчива к шуму любого происхождения и умеренно устойчива к JPEG/blur; требуется входной контроль качества изображений.
Adversarial robustness	ПР3	Robust Performance / ASR / R-AUC	PGD-10: FR=1,000 при ε=1/255 (197/197); R-AUC_ε=0,032; Validity Rate=1,000; FGSM FR=0,558 (ε=1/255)	FR [0,9809;1,0000]; R-AUC_ε [0,0303;0,0348]	В исследованной white-box модели нарушителя (untargeted, L_∞, $\varepsilon \le 16/255$) модель не обладает состязательной устойчивостью; защита не реализована — вывод ограничен данным бюджетом и целью.
Privacy	ПР4	MIA ROC-AUC / TPR@FPR	ROC-AUC≈0.5561; Attack Acc=0.5460; TPR@FPR1%=0.0000; gap=2,8 п.п.	AUC [0.5060; 0.6072]; AA [0.5022; 0.5891]	Слабый, пограничный сигнал членства в пределах исследованного протокола; BCa-интервал loss отстоит от 0,5 лишь на 0,0017, BCa для entropy включает 0,5; при низких FPR атака почти бесполезна; область применимости ограничена image-level privacy unit и отсутствием patient-level метаданных.

9. Ограничения проведённого исследования

- Единица приватности ПР4 — image-level вместо рекомендованной для медицинских данных «пациент» (§5.2): идентификаторов пациентов в метаданных нет (проверено), поэтому patient-level протокол непостроим; правило о несмешивании объектов одного субъекта между member/non-member при image-level единице не гарантируется; внутрипациентные корреляции RSNA не контролируются (см. п. 7 ПР4).
- Adversarial training не выполнялся: методика ПР3 (§4) требует оценки, а не защиты; чекпоинт заморожен (§1). Представлен только анализ атак — выводы об устойчивости ограничены отсутствием защитных механизмов.
- Независимый чекер выполнен в варианте APGD-CE на подмножестве 20 снимков (§4.6): это не полный AutoAttack; APGD-T/FAB-T и DLR-лоссы не использовались, полная композиция AutoAttack на двухклассовой задаче не запускалась. Реализация torchattacks APGD утекает VRAM при бюджете GPU 4 ГБ, что и ограничило объём проверки.
- Шкалы шума в ПР2 перекалиброваны на сублиминальные уровни (§3.2): модель коллапсирует уже при σ≥0,02, поэтому крупные уровни давали плоскую кривую; требование «>= 4 ненулевых уровней» и «>= 2 типов» сохранено (4 типа × 5 уровней).
- Детерминированные коррупции (размытие, JPEG) имеют одну реализацию — у них нет стохастичности; вместо >= 5 реализаций вариативность учтена иерархическим bootstrap по объектам (§3.4). Для стохастических коррупций использовано r = 5 реализаций.
- Коррупции реализованы собственными эквивалентными функциями (NumPy/OpenCV/Pillow) вместо рекомендуемых imagecorruptions/Albumentations (§3.3, §8): параметры соответствуют каноническим определениям (гауссов/пуассоновский шум, размытие, JPEG), torchvision применяется в препроцессинге; это ограничение сопоставимости с внешними бенчмарками.
- MIA: не реализованы shadow-model и LiRA (§5.2 — опциональные), результаты относятся к базовой loss-threshold-атаке. Порог подбирался на отдельной калибровочной половине и не переоптимизировался на evaluation. Единица приватности — image-level: patient-level оценка невозможна из-за отсутствия ID пациентов; дубликаты train↔test могут как усиливать, так и ослаблять сигнал, направление суммарного эффекта не измерено.
- Вычислительные бюджеты (GPU 4 ГБ) ограничили сценарии: часть стратифицированных серий и расширенную выборку для AutoAttack; время исполнения ПР2/ПР3 превышает ориентир «<= 30 мин CPU». Инференс выполнялся на GPU (CUDA) — переход CPU → GPU качественно не менял результаты.
- Исправление по результатам внешнего аудита (VERIFICATION_REPORT.md): устранён дефект data-flow в сборке таблицы профиля ПР1 (строки Anomalies прежде получали интервалы из блока утечек), добавлены Attack Accuracy/интервалы TPR@FPR в ПР4, Validity Rate и L_2/L∞-статистики в ПР3, исправлен bootstrap R-AUC ПР2 (пересчёт всей кривой на перевыборке) и проведён чистый прогон ПР3 без кэша.

10. Вывод о том, при каких условиях и в отношении каких свойств модели можно доверять

В исследованных условиях модель демонстрирует: (а) высокое качество решения задачи на чистых снимках (M(0) = 0,9833 [0,9711; 0,9904]); (б) отсутствие распределительного сдвига train/test; (в) малый лейбл-шум; (г) умеренную устойчивость к JPEG и размытию. При этом модель НЕ демонстрирует: (д) устойчивости к шуму (значимое падение при σ = 0,005); (е) состязательной устойчивости в исследованном бюджете (FR = 1,000 при ε = 1/255); (ж) отсутствия членство-сигнала (обнаружен слабый, пограничный сигнал: BCa-интервал loss отстоит от 0,5 лишь на 0,0017, BCa для entropy включает 0,5).

Область применимости вывода ограничена: выбранными данными (7200 снимков, сплит 80/10/10), классами искажений (4 типа × 5 уровней), моделью нарушителя (white-box, untargeted, L∞, ε ≤ 16/255), протоколом MIA (image-level, loss-threshold; порог — на отдельной калибровке) и статистической неопределённостью (95% интервалы). Дополнительные ограничения — дубликаты и файловая утечка train↔test, отсутствие patient-level метаданных, отсутствие защитных механизмов (adversarial training).

Практические условия допустимого использования: (1) обязательный входной контроль качества изображений (детекция шума/размытия) до инференса; (2) использование модели только как вспомогательного инструмента triage под контролем клинициста; (3) мониторинг сдвига и калибровки уверенности; (4) состязательное дообучение и повторная валидация устойчивости — условие перехода к более широкому применению.

Рекомендации (следующие шаги):

- Ввести входной контроль качества изображений с блокировкой инференса при выходе за границы.
- Провести состязательное дообучение и повторно измерить устойчивость (ПР2/ПР3) как приёмку.
- Перестроить разбиение данных с учётом дубликатов и (при наличии) ID пациентов для устранения утечки train↔test и корректной оценки patient-level приватности.
- Ввести мониторинг сдвига/калибровки; учитывать слабый членство-сигнал в политике доступа.
- Для публикации — повторить MIA с shadow-моделями и LiRA и расширить подмножество AutoAttack.

Приложение А. Артефакты цикла

- Ноутбуки: PR1.ipynb, PR2.ipynb, PR3.ipynb, PR4.ipynb (исполнены, сохранены с выводами).
- Результаты: results/baseline_eval.json, pr1_quality_profile.csv, pr1_image_stats.csv, pr1_label_inspection.csv, pr1_label_quality.json, pr1_shift.json, pr1_niqe_brisque.csv, pr2_summary.json, pr2_summary_table.tsv, pr2_rauc.csv, pr2_correctness.pkl,

pr3_adv_attacks.csv, pr3_validity_l2.csv, pr3_multiseed_pgd.csv, pr3_rauc.csv, pr3_summary.json, pr3_autoattack.json, pr3_masks.pkl, pr4_mia.json, pr4_scores.npz.

- Рисунки: figures/pr1_duplicates_examples.png, pr1_label_issues.png, pr1_brightness_blur.png, pr2_robustness_curves.png, pr2_corruption_examples.png, pr3_robustness_vs_eps.png, pr3_adversarial_examples.png, pr4_mia_attack.png.
- Воспроизводимость: reproducibility.json, requirements_pr_cycle.txt, execute_notebook.py, common.py, organize_data.py, eval_baseline.py.
- Пакеты V2 (каждый — с манифестом SHA-256, отчётом PDF+DOCX, конфигурацией, метриками, MISSING_ITEMS.md и проверкой целостности): PRELIMINARY_SUBMISSION_V2 — 14 файлов, 13 строк манифеста, ZIP 43 237 706 байт; PR1_SUBMISSION_V2 — 23 файла, 22 строки, ZIP 47 973 214 байт; PR2_SUBMISSION_V2 — 20 файлов, 19 строк, ZIP 54 841 748 байт; PR3_SUBMISSION_V2 — 20 файлов, 19 строк, ZIP 49 266 632 байт; PR4_SUBMISSION_V2 — 20 файлов, 19 строк, ZIP 42 701 012 байт. Манифесты не содержат собственного хеша; `sha256sum -c` и проверка ZIP проходят без ошибок. Ключевые унаследованные хеши совпадают во всех пакетах: best_model.pth — 0ba793cb…b504f0 (44 789 835 байт), training_history.json — 18743f1e…69cfc, dataset_source.md — 2b542c08…a7b0, requirements.txt — 7113f58e…7ff0a.

Приложение В. Версии библиотек

torch 2.9.1+cu130, torchvision 0.24.1+cu130, numpy 2.3.3, scipy 1.16.2, sklearn 1.7.2, pandas 2.3.3, PIL 11.3.0, matplotlib 3.10.6, seaborn 0.13.2, cleanlab 2.9.0, imagehash 4.3.2, torchattacks 3.5.1, pyiqa 0.1.16, cv2 5.0.0, skimage 0.26.0, scipy_note используется также для BCa-bootstrap (scipy.stats.bootstrap)

Seed = 42; bootstrap перевыборок = 2000; уровень доверия = 0.95.