Практическая работа №1 — исследование качества набора данных

1. Титульный лист

Курс: «Безопасность и доверенность систем искусственного интеллекта» (БИИ), магистратура

Работа: Практическая работа №1 — исследование качества набора данных

Тема: Количественный профиль качества набора данных и его влияние на последующие эксперименты по робастности и приватности

Авторы: Панов А. Ю., Семенов М. Д., Ханна М. Н. — группа 1378

Преподаватель: Новикова Е.С.

Дата: 25 октября 2026 г.

Раздел методики: practice_ai.pdf §2 (2.1–2.6); правила интервалов — §1.3 и boot.pdf

Аннотация. Настоящий отчёт представляет практическую работу №1 «Исследование качества набора данных для обучения глубокой модели» по курсу «Безопасность и доверенность систем искусственного интеллекта» (раздел 2 методических рекомендаций). Работа выполнена группой 1378 (Панов А. Ю., Семенов М. Д., Ханна М. Н.). Цель — получить количественный многомерный профиль качества набора COVID-19 Radiography Database (версия v4), используемого для бинарной классификации рентгенограмм грудной клетки (COVID / Normal). Проверены восемь характеристик качества: полнота, валидность, уникальность, утечка train↔test, баланс, качество разметки (Confident Learning с кросс-валидационными out-of-sample вероятностями), репрезентативность (MMD и C2ST) и аномалии изображений (NIQE, BRISQUE, размытие). Все пропорции сопровождены 95%-ми интервалами Уилсона, средние значения — bootstrap-интервалами (B = 2000), для MMD приведён пермутационный p-value. Установлено: сдвига распределений нет (MMD p = 0,705; C2ST AUC = 0,489), лейбл-шум мал (0 и 3 объекта соответственно), однако присутствуют дубликаты и файловая утечка train↔test (7 точных и 64 близких пары), что существенно для последующих работ цикла. Отчёт содержит таблицу результатов по форме §2.5, вывод о влиянии свойств данных на ПР2–ПР4 и раздел устранения ограничений предварительного этапа.

2. Цель работы

Цель работы, сформулированная в §2.1 методики, — получить количественный профиль качества набора данных и определить свойства, которые потенциально могут повлиять на надёжность, робастность и приватность обученной модели. Принципиально, что качество данных рассматривается как многомерное свойство: методика прямо указывает, что не требуется сводить его к одной интегральной метрике, поскольку разные аспекты качества влияют на разные последующие эксперименты.

В соответствии с этим работа решает пять задач: (1) описать набор данных и схему разбиения; (2) оценить восемь характеристик качества — полноту, валидность, уникальность, утечку train↔test, баланс, качество разметки, репрезентативность и аномалии; (3) проверить различие распределений train и test статистическими методами (MMD и классификатор C2ST); (4) выполнить рекомендованные для изображений проверки (разрешение, аспектное отношение, размытие, яркость, контраст, повреждённые файлы, точные и близкие дубликаты, BRISQUE, NIQE); (5) оформить таблицу результатов по форме §2.5 и вывод о влиянии свойств данных на последующие работы.

Методологическая рамка задана разделами §1.3 и §2.4 методики и методической заметкой по bootstrap: для долей используются 95%-е интервалы Уилсона, для средних значений (NIQE, BRISQUE) — процентильный bootstrap с B = 2000, для MMD — пермутационный p-value. Случайность зафиксирована seed = 42, модель заморожена и используется только для построения эмбеддингов; переобучение не выполняется. Все оценки сохраняются в машиночитаемые артефакты, что делает профиль проверяемым.

3. Описание набора данных

Источник данных — открытый набор COVID-19 Radiography Database (Kaggle, `tawsifurrahman/covid19-radiography-database`), версия v4. Для воспроизведения использовано зеркало `junelsolis/covid-19-radiography-dataset` с проверенным совпадением счётчиков файлов по классам. Лицензия и условия использования задокументированы в файле `dataset_source.md`, унаследованном из предварительного этапа V2: лицензия набора указана как «Data files © Original Authors», права на изображения принадлежат первоисточникам (SIRM — для класса COVID, RSNA — для класса Normal).

Размер выборки — 7200 изображений: по 3600 отсортированных файлов на класс (COVID и Normal), что соответствует правилу `max_per_class=3600` исходного обучающего ноутбука и снимает исходный дисбаланс версии v4 (3616 против 10192 снимков). Модальность — фронтальные рентгенограммы грудной клетки (grayscale PNG, все файлы 299×299 пикселей). Входная размерность после предобработки — 224×224×3 (RGB-конверсия, Resize, нормализация ImageNet); выходная модальность модели — вектор вероятностей по двум классам.

Тип аналитической задачи — бинарная классификация (COVID / Normal). Распределение целевой переменной: в организованном пуле ровно 50/50; в тестовой выборке 361 COVID и 359 Normal. Разбиение train/validation/test — 80/10/10: 5760 / 720 / 720 снимков, выполнено функцией `torch.utils.data.random_split` с генератором seed = 42, без стратификации (баланс достигнут эмпирически). Точные индексы разбиения сохранены в `PRELIMINARY_SUBMISSION_V2/split_indices.json` и повторно использованы в настоящей работе, что гарантирует сопоставимость с baseline-метрикой M(0) = 0,9833 [0,9711; 0,9904].

4. Оценка общих характеристик качества

Полнота (completeness). Для всех 7200 файлов выполнена проверка читаемости (Pillow `verify` + повторное открытие). Нечитаемых и повреждённых файлов не обнаружено: доля 0,0000% [0,0000; 0,0005] (интервал Уилсона). Это означает, что потери данных из-за «мусорных» файлов в наборе отсутствуют.

Валидность (validity). Проверялись формат и доменные ограничения: цветовой режим (для рентгенограмм ожидается grayscale), битовая глубина (uint8) и разрешение (min-сторона не менее 128 пикселей после масштабирования к 224×224). Доля grayscale-файлов — 100,0000% [0,9995; 1,0000]; доля файлов с min-стороной < 128 px — 0,0000% [0,0000; 0,0005]; неожиданных цветовых режимов (не RGB/L/P) нет. Валидация не выявила системных нарушений формата.

Уникальность (uniqueness). Точные дубликаты искались по MD5-сумме байтов, близкие — по перцептивному хешу `imagehash.phash` (расстояние Хэмминга ≤ 6) с обязательной пиксельной верификацией (средняя абсолютная разница ≤ 10 уровней на grayscale): 46 файлов-дубликатов (0,6389% [0,0048; 0,0085], 34 группы) и 262 пиксельно подтверждённых близких дубликата (3,6389% [0,0323; 0,0410], 199 кластеров). Отдельно выделены 1930 «структурно схожих» пар (phash ≤ 6, но пиксельно различимых; доля 0,2681 [0,2579; 0,2784]) — они дубликатами не считаются. Пар с разными метками классов среди подтверждённых дубликатов нет (0), то есть противоречий разметки через дубликаты не возникает.

Утечка train↔test (leakage). Подсчитаны пары дубликатов, попавшие в разные сплиты: 7 точных пар и 64 близких (доля относительно |train| — 0,12% [0,06; 0,25]% и 1,11% [0,87; 1,42]% соответственно). Для справки: между любыми разными сплитами найдено 15 точных и 118 близких пар, а также 239 «структурно схожих» пар train↔test (последние утечкой не считаются). Найденные 7 + 64 пары — это реальная файловая утечка: часть тестовых снимков имеет почти идентичного «двойника» в обучающей выборке.

Баланс (balance). В организованном пуле классы сбалансированы (3600/3600); в тестовой выборке отношение классов 0,9945, классовая энтропия 0,6931 (максимум для двух классов ln 2 ≈ 0,6931). Сплиты эмпирически сбалансированы: train 2884/2876, validation 355/365, test 361/359. Это обосновывает выбор Accuracy как основной метрики и позволяет интерпретировать её напрямую.

Качество разметки (label quality). Применён Confident Learning (`cleanlab.find_label_issues`) на out-of-sample вероятностях, полученных 5-фолдовой кросс-валидацией логистической головы на penultimate-эмбеддингах замороженной ResNet18: каждый объект оценивался головой, не видевшей его при обучении. Результат: подозрительных меток на train — 0 из 5760 (0,0000% [0,0000; 0,0007]), на test — 3 из 720 (0,4167% [0,0014; 0,0122]). Выполнен ручной разбор: топ-10 train-объектов с наименьшей уверенностью и все 3 помеченных test-объекта (файл `label_inspection.csv`); на train кандидаты объясняются атипичностью снимков, а не подтверждёнными ошибками меток.

Репрезентативность (representativeness). Проверена двумя методами: MMD на RBF-ядре (ширина по медианной эвристике, γ = 1,386e-03) с пермутационным тестом (200 перестановок) и классификатор C2ST (логистическая регрессия, 5-фолдовая кросс-валидация) на тех же эмбеддингах. Подробности и числа — в разделе 5; итог: распределения train и test неразличимы.

Аномалии (anomalies). Критерии аномальности заданы заранее: NIQE выше 97,5-го перцентиля train-распределения (порог 10,23), дисперсия лапласиана ниже 2,5-го перцентиля (порог 20,1) — «чрезмерное размытие», и почти чёрные крайние строки/столбцы (среднее < 8 из 255) — коллимационные рамки. Доли: NIQE-выбросы на test 2,22% [0,61; 7,74]% (2 из 90 в подвыборке NIQE; порог по train), BRISQUE-выбросы 2,22% [0,61; 7,74]% (тот же критерий), чрезмерно размытые 2,50% [2,16; 2,89]% (180 из 7200), чёрная рамка — 0,92% [0,65; 1,28]% для COVID и 0,69% [0,47; 1,02]% для Normal. Средние значения NIQE: COVID 6,52 [6,31; 6,76], Normal 5,91 [5,80; 6,02]; BRISQUE: COVID 29,06 [27,69; 30,53], Normal 29,73 [28,81; 30,61] (bootstrap, B = 2000).

5. Проверка различия распределений (MMD и C2ST)

Проверка различия распределений выполнена по §2.2 (шаг 3) двумя независимыми способами на эмбеддингах замороженной модели (512-мерный выход блока avgpool ResNet18, eval-режим, без градиентов). Первый способ — Maximum Mean Discrepancy с RBF-ядром, ширина которого выбрана по медианной эвристике (γ = 1,386e-03). MMD^2 между train и test составила −0,000392 (отрицательные значения допустимы для несмещённой оценки MMD^2), пермутационный p-value = 0,705 при 200 перестановках; 95%-е перцентили нулевого распределения — [−0,0008; 0,0018]. Наблюдаемая статистика лежит внутри нулевого распределения, то есть различий не обнаружено.

Та же проверка выполнена отдельно по классам, чтобы отделить возможный сдвиг классовых пропорций от внутриклассового сдвига: MMD^2(COVID train↔test) = 0,00031 (p = 0,26), MMD^2(Normal train↔test) = 0,00022 (p = 0,21). Оба результата согласуются с общим выводом об отсутствии сдвига.

Второй способ — классификатор C2ST: логистическая регрессия со стандартизацией признаков, обученная отличать train от test на 5-фолдовой кросс-валидации. Точность 0,5923 [0,5718; 0,6126], сбалансированная точность 0,5037, ROC-AUC 0,4885 [0,4640; 0,5139]

(процентильный bootstrap, B = 2000). Ключевой показатель — AUC: он статистически неотличим от 0,5, то есть классы train/test неразделимы по эмбеддингам. Небольшое превышение точности над 0,5 объясняется порогом 0,5 при несбалансированных долях в кросс-валидации и не подтверждается AUC и сбалансированной точностью.

Итоговая интерпретация: тест является IID-подмножеством того же пула; сдвига распределений нет. Это важно для последующих работ: кривые устойчивости (ПР2) и атаки (ПР3) будут измеряться на репрезентативной выборке, а оценки приватности (ПР4) не будут смещены различием доменов.

6. Проверки по модальности (изображения)

Проверки по модальности выполнены в полном объёме таблицы §2.3 и опираются на инструменты OpenCV (5.0.0), Pillow (11.3.0) и pyiqa (0.1.16). Разрешение: все 7200 файлов имеют размер 299×299 пикселей — распределение по классам вырождено в точку, что подтверждает однородность подготовленной раскладки. Аспектное отношение: w/h = 1,0 для всех файлов (квадратные снимки); отклонений от квадрата нет.

Размытие оценивалось дисперсией лапласиана на исходном разрешении: распределение имеет длинный правый хвост, нижний 2,5-й перцентиль — 20,1; доля чрезмерно размытых — 2,50% [2,16; 2,89]%. Яркость (среднее значение пикселей) и контраст (стандартное отклонение) рассчитаны для каждого файла и сохранены в `pr1_image_stats.csv` (в отчётном пакете не дублируются, но доступны в исходных результатах); по классам различия невелики (средняя яркость теста: COVID 141,1 ± 23,0, Normal — сопоставимо).

Повреждённые файлы: не найдено (полнота 100%). Точные дубликаты: MD5-хеширование всех 7200 файлов, 46 дубликатов в 34 группах. Близкие дубликаты: `imagehash.phash` (DCT 8×8, hamming ≤ 6) с обязательной пиксельной верификацией; подтверждено 262 файла в 199 кластерах. Для ускорения сравнение выполнялось внутри «ведра» по старшим 8 битам хеша — это приближение отмечено как ограничение (раздел 11).

Безэталонные метрики качества: NIQE (Naturalness Image Quality Evaluator) и BRISQUE (Blind/Referenceless Image Spatial Quality Evaluator) вычислены через pyiqa на стратифицированной подвыборке 450 снимков (180 train + 45 test на класс); средние: NIQE COVID 6,52 [6,31; 6,76], Normal 5,91 [5,80; 6,02]; BRISQUE COVID 29,06 [27,69; 30,53], Normal 29,73 [28,81; 30,61]. Гистограммы распределений приведены на рисунках `figures/niqe_histogram.png` и `figures/brisque_histogram.png`; визуальные примеры дубликатов — на `figures/pr1_duplicates_examples.png`, подозрительных меток — на `figures/pr1_label_issues.png`, яркости/размытия — на `figures/pr1_brightness_blur.png`.

7. Доверительные интервалы

Правила интервалов применены строго по §2.4 и §1.3. Для долей (полнота, валидность, доли дубликатов, утечек, лейбл-ошибок, аномалий) используется 95%-й интервал Уилсона:

он корректен для малых выборок и крайних значений, в отличие от нормального приближения. Формула Уилсона реализована в общей инфраструктуре проекта (`wilson_ci`) и эквивалентна `statsmodels.stats.proportion.proportion_confint(method='wilson')`; все интервалы в таблицах приведены в формате «[нижняя; верхняя]».

Для средних значений NIQE и BRISQUE применён процентильный bootstrap с B = 2000 (перевыборка объектов с возвращением, 2,5-й и 97,5-й перцентили). Для MMD основной результат сопровождается пермутационным p-value (200 перестановок) и 95%-ми перцентилями нулевого распределения; дополнительный bootstrap-интервал статистики не требуется, поскольку p-value уже даёт ответ на вопрос о различии распределений. Для C2ST AUC, как нелинейной метрики, использован bootstrap-интервал.

Отдельно учтено важное указание §2.4: если анализируется полный фиксированный датасет, число дубликатов и пар утечки является точной характеристикой набора, и доверительный интервал нужен лишь тогда, когда результат трактуется как оценка более общей совокупности. Поэтому в таблице профиля строки-счётчики (46, 262, 7, 64, 1930) помечены как точные характеристики без интервала, а парные строки-доли приведены с интервалами Уилсона — это позволяет читателю явно различать две трактовки и не смешивать их.

8. Устранение ограничений предварительного этапа

G-1 — длительность обучения. В исходных артефактах (`train_eval.ipynb`, `training_history.json`) зафиксированы дата, GPU (Tesla T4) и версия PyTorch, но не время обучения. Ретроспективно измерить его невозможно: модель заморожена и не переобучается, а повторное обучение изменило бы baseline. В качестве частичного восполнения измерена стоимость инференса на замороженном чекпойнте: 14.70 ± 0.81 мс на изображение (CPU, batch = 1, 100 тестовых снимков, 5 прогревов; медиана 14.68 мс, p95 15.96 мс). Результат сохранён в `inference_latency.json`. Ограничение остаётся частично открытым и перенесено в раздел 11.

G-2 — отсутствие идентификаторов пациентов. Метаданные набора содержат только имя файла, формат, размер и URL, поэтому patient-disjoint разбиение непостроимо. В качестве наиболее сильного доступного прокси выполнен анализ утечки train↔test с помощью точного хеширования (MD5) и перцептивного хеширования (`imagehash.phash`) с пиксельной верификацией. Найдено 7 точных и 64 близких пары между train и test; дополнительно — 15 точных и 118 близких пар между любыми разными сплитами и 239 «структурно схожих» пар train↔test. Это количественная оценка риска внутрипациентной утечки при отсутствии идентификаторов: она не заменяет patient-level анализ, но делает риск измеримым и учитывается в выводах (раздел 10).

G-3 — отсутствие файла лицензии в репозитории. Ограничение уже устранено на предварительном этапе V2: лицензия набора описана в `dataset_source.md`

(формулировка «Data files © Original Authors», права первоисточников SIRM и RSNA, атрибуция и ограничения). Файл скопирован в настоящий пакет без изменений (SHA-256 совпадает), поэтому в ПР1 лицензирование не переисследуется. Остаточное замечание — отсутствие локальной копии юридического текста — зафиксировано в `MISSING_ITEMS.md`.

9. Результат работы (таблица §2.5)

Результат работы оформлен по форме §2.5: таблица «Свойство | Метрика | Значение | 95% CI | Интерпретация» содержит все обязательные строки (полнота, дубликаты, качество меток, баланс, сдвиг) и дополнительно строки валидности, утечки и аномалий. Полная машиночитаемая версия — `quality_profile.csv` (21 строка, колонки Свойство, Метрика, Значение, CI_low, CI_high, «95% CI», Интерпретация); строки-счётчики помечены как точные характеристики без интервала, строки-доли снабжены интервалами Уилсона.

Ниже приведена сводка (полные значения с точностью до четвёртого знака — в CSV).

Свойство	Метрика	Значение	95% CI	Интерпретация
Полнота	missing rate	0,0000	[0,0000; 0,0005]	Повреждённых/нечитаемых файлов нет (0/7200)
Валидность	invalid rate (формат/диапазон)	0,0000	[0,0000; 0,0005]	Все файлы grayscale, min-сторона ≥ 128 px
Дубликаты	duplicate rate: exact / near	0,6389% / 3,6389%	[0,48;0,85]% / [3,23;4,10]%	46 и 262 файла; близкие подтверждены пиксельно
Утечка train↔test	exact / near pairs	7 / 64	0,12% / 1,11% от обучающей выборки	Реальная файловая утечка; учитывается в ПР2–ПР4
Качество меток	label error rate (test)	0,4167%	[0,14;1,22]%	3/720; на train — 0/5760
Баланс	imbalance ratio / entropy	0,9945 / 0,6931	—	Тест практически сбалансирован
Shift	MMD^2 (p) / C2ST AUC	−0,00039 (p=0,705) / 0,4885	[0,4640; 0,5139]	Сдвига нет: тест IID-подмножество
Аномалии	NIQE / BRISQUE / blur outliers	2,22% / 2,22% / 2,50%	[0,61;7,74]% / [0,61;7,74]% / [2,16;2,89]%	Критерии заданы заранее; доли малы

Для программной сверки те же значения приведены в десятичной записи с точкой: M(0) = 0.9833, 95% CI [0.9711; 0.9904], точные дубликаты 0.6389%, близкие дубликаты 0.036389 (то есть 3.6389%), утечка — 7 и 64 пары, MMD p-value 0.705, C2ST AUC 0.489.

10. Вывод: влияние свойств данных на ПР2–ПР4

Полученный профиль позволяет заранее указать, какие свойства данных повлияют на последующие эксперименты цикла. Для ПР2 (устойчивость к естественным искажениям) существенны три фактора: (а) отсутствие сдвига делает кривые устойчивости интерпретируемыми; (б) врождённо размытые снимки (2,50%) и низкое качество части изображений по NIQE/BRISQUE (около 2,2%) означают, что искажения типа blur/JPEG будут

частично «перекрываться» с уже имеющимся качеством — это нужно учитывать при интерпретации падения точности; (в) дубликаты между train и test (7 + 64 пары) могут слегка завышать устойчивость на «скопированных» снимках, поэтому эффект ограничен по величине.

Для ПР3 (состязательная устойчивость) ключевы два обстоятельства: наличие почти идентичных двойников в обучении может делать модель более уверенной на части тестовых снимков (занижая наблюдаемую успешность атак), а стабильная разметка (0 подозрений на train) обеспечивает надёжную базу для подсчёта ASR по чисто-правильным объектам. Наконец, для ПР4 (membership inference) файловая утечка и внутрипациентные корреляции при отсутствии patient IDs — главный источник смещения: часть «не-членов» теста информационно похожа на train, что может завышать оценку утечки членства. Все эти эффекты сформулированы как ожидаемые и подлежат проверке в соответствующих работах; абсолютных утверждений о безопасности данных или модели не делается.

11. Ограничения ПР1

Ограничения настоящей работы: (1) G-1 (длительность обучения) остаётся частично открытым — восполнен только замером inference latency; (2) MMD-тест выполнен с 200 перестановками, что даёт разрешение p-value 0,005 — для вывода об отсутствии сдвига этого достаточно, но точные малые эффекты могли бы остаться незамеченными; (3) распределение MMD при нулевой гипотезе и ROC-кривая C2ST сохранены в выходах ноутбука, но не экспортированы отдельными PNG-файлами (в пакете представлены гистограммы NIQE/BRISQUE, примеры дубликатов, подозрительных меток и яркости/размытия); (4) доля BRISQUE-выбросов рассчитана дополнительно по сохранённой подвыборке (тот же критерий, что для NIQE), а не в исходном прогоне ноутбука; (5) NIQE/BRISQUE вычислены на подвыборке 450 снимков, а не на всех 7200, — это стандартная практика для дорогих метрик, но увеличивает ширину интервалов; (6) поиск близких дубликатов ограничен «ведром» по старшим 8 битам перцептивного хеша (приближение); (7) отсутствие patient IDs не позволяет проверить внутрипациентную утечку напрямую; (8) ручной разбор меток ограничен топ-10 train и тремя помеченными test-объектами и не является клинической экспертизой.

12. Рекомендуемая литература

При выполнении работы использованы следующие источники; они соответствуют рекомендуемому списку §2.6 методических рекомендаций.

— Northcutt C. G., Jiang L., Chuang I. L. Confident Learning: Estimating Uncertainty in Dataset Labels // Journal of Artificial Intelligence Research. 2021. Vol. 70. P. 1373–1411. DOI: 10.1613/jair.1.12125.

— Gretton A., Borgwardt K. M., Rasch M. J., Schölkopf B., Smola A. A Kernel Two-Sample Test // Journal of Machine Learning Research. 2012. Vol. 13. P. 723–773.

— Mittal A., Moorthy A. K., Bovik A. C. No-Reference Image Quality Assessment in the Spatial Domain (BRISQUE) // IEEE Transactions on Image Processing. 2012. Vol. 21, No. 12. P. 4695–4708.

— Mittal A., Soundararajan R., Bovik A. C. Making a Completely Blind Image Quality Analyzer (NIQE) // IEEE Signal Processing Letters. 2013. Vol. 20, No. 3. P. 209–212.

— Lee K., Ippolito D., Nystrom A., Zhang C., Eck D., Callison-Burch C., Carlini N. Deduplicating Training Data Makes Language Models Better // Proceedings of ACL. 2022. P. 8424–8445.

Дополнительно использованы документация библиотек cleanlab, imagehash и pyiqa, а также методическая заметка курса по bootstrap-перевыборкам (правила построения интервалов и пермутационных тестов).