Курс: «Безопасность и доверенность систем искусственного интеллекта» (БИИ), магистратура

Работа: Предварительный этап практического цикла — отчёт

Тема: Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки: базовая модель и протокол вычислительного эксперимента

Авторы: Панов А. Ю., Семенов М. Д., Ханна М. Н. — группа 1378

Базовый проект: mina_covid-xray-detector (чекпойнт best_model.pth)

Дата: 25 октября 2026 г.

Преподаватель: Новикова Е.С.

ПРЕДВАРИТЕЛЬНЫЙ ЭТАП ПРАКТИЧЕСКОГО ЦИКЛА

Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки

Аннотация

Настоящий отчёт фиксирует результаты предварительного этапа практического цикла курса «Безопасность и доверенность систем искусственного интеллекта». В соответствии с разделом 1 методических рекомендаций (practice_ai.pdf §1) на предварительном этапе сформулирована аналитическая задача и контекст применения модели, выбран и описан набор данных, определены входная и выходная модальности, сформированы обучающая, валидационная и тестовая выборки, выбрана архитектура глубокой модели и обучена baseline-модель, определена основная метрика качества, а модель и все параметры вычислительного эксперимента зафиксированы для воспроизводимости. Обученная baseline-модель (ResNet18, transfer learning) достигла точности M(0) = 0,9833 с 95%-м доверительным интервалом Уилсона [0,9711; 0,9904] на неизменённом тестовом наборе из 720 снимков; результат в точности воспроизводится из сохранённого чекпойнта best_model.pth и совпадает с фиксацией training_history.json. Согласно завершающему правилу раздела 1, базовая модель будет использоваться во всех четырёх практических работах без изменения параметров; результаты ПР1–ПР4 в настоящий отчёт не включаются.

2. Описание предметной области и аналитической задачи

Предметная область — медицинская визуализация: автоматический анализ фронтальных рентгенограмм грудной клетки. Аналитическая задача — бинарная классификация снимка по признаку COVID-19: класс «COVID» (положительный) против класса «Normal» (здоровый). Решение принимается по одному изображению, без использования

метаданных пациента или анамнеза. Задача выбрана как типичный представитель медицинского машинного обучения: у неё простая и клинически интерпретируемая структура ошибок, общедоступные данные и компактная бинарная постановка, удобная для систематического исследования свойств доверенности.

Контекст применения модели — вспомогательный инструмент сортировки (triage) при скрининге потока пациентов: модель помечает и ранжирует снимки, окончательное решение остаётся за клиницистом. Система не предназначена для автономной постановки диагноза. Класс COVID является целевым положительным классом; пропуск случая (ложный отрицательный, FN) ведёт к распространению инфекции и задержке лечения, а ложная тревога (ложный положительный, FP) — к необоснованной изоляции и лишнему дообследованию. Асимметрия последствий ошибок превращает качество модели в вопрос безопасности, а не только точности, и мотивирует последующий анализ устойчивости и приватности.

Связь с курсом: на одном и том же объекте исследования (один набор данных + одна базовая модель) в последующих практических работах последовательно исследуются доверенные свойства: качество данных (ПР1), устойчивость к естественным искажениям (ПР2), состязательная устойчивость (ПР3) и приватность обучающей выборки (ПР4). Предварительный этап фиксирует «точку отсчёта» — замороженную baseline-модель и её метрику с доверительным интервалом, относительно которой будут измеряться все последующие изменения доверенных свойств.

3. Описание набора данных

Источник данных — открытый Kaggle-набор «COVID-19 Radiography Database» (tawsifurrahman/covid19-radiography-database), версия v4, на которую ссылается исходный ноутбук Covid_detector.ipynb (команда kaggle datasets download -d tawsifurrahman/covid19-radiography-database). Состав версии v4: COVID — 3616, Normal — 10192, Lung_Opacity — 6012, Viral Pneumonia — 1345 снимков. Для бинарной задачи курса используются только классы COVID и Normal.

Ноутбук организует подвыборку по правилу organize_dataset(..., max_per_class=3600): первые 3600 отсортированных файлов каждого класса копируются в плоскую ImageFolder-структуру organized_data/{COVID, Normal}; итоговый пул — 7200 снимков (3600 + 3600). Такое отсечение снимает исходный дисбаланс v4 (3616 против 10192) и выравнивает классы. Поскольку Kaggle API локально недоступен (ошибка 403 без учётных данных), для воспроизведения использовано зеркало github.com/junelsolis/covid-19-radiography-dataset, у которого количество файлов по каждому классу точно совпадает с v4; тождество состава подтверждено попарным подсчётом файлов по классам.

Модальность данных — фронтальные рентгенограммы грудной клетки (grayscale PNG); в организованном пуле все файлы имеют размер 299×299 пикселей. Распределение классов

в организованном пуле — сбалансированное (3600/3600). Лицензия набора, указанная на его странице на Kaggle, — «Data files © Original Authors»: файлы данных принадлежат авторам набора, явная открытая лицензия для перераспространения не заявлена; отдельного файла лицензии в репозитории проекта нет (см. раздел 11).

4. Входная и выходная модальности

Входная модальность — RGB-изображение размера 224×224×3. Исходный PNG-снимок является полутоновым (grayscale) и конвертируется в трёхканальный вид (три одинаковых канала), после чего приводится к размеру 224×224 билинейной интерполяцией (torchvision.transforms.Resize). Такой вход совместим с архитектурой ResNet18, предобученной на трёхканальных ImageNet-изображениях.

Пайплайн предобработки инференса (единый во всех артефактах цикла, включая приложение app.py): Resize((224, 224)) → ToTensor() → Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]) (нормализация ImageNet). Обучающий пайплайн дополняет эту цепочку аугментациями — RandomHorizontalFlip(p=0.5), RandomRotation(10°), ColorJitter(brightness=0.2, contrast=0.2) — которые применяются исключительно к обучающей выборке; валидационная и тестовая выборки обрабатываются тем же пайплайном, что и инференс.

Выходная модальность — вектор логитов размерности 2, преобразуемый функцией softmax в вероятности P(COVID) и P(Normal); итоговый ответ системы — класс с максимальной вероятностью и её численное значение (реализовано в app.py: torch.softmax → argmax). Тождество пайплайна инференса в ноутбуке, в программае воспроизведения baseline и в приложении — обязательное условие сопоставимости результатов всех практических работ цикла.

5. Схема разбиения train/validation/test

Схема разбиения воспроизводит исходный ноутбук: torchvision.datasets.ImageFolder сортирует классы по алфавиту (COVID = 0, Normal = 1), после чего применяется torch.utils.data.random_split с пропорциями 80/10/10 и генератором со случайным seed 42. Итоговые размеры: обучающая выборка — 5760 снимков, валидационная — 720, тестовая — 720. Случайный seed зафиксирован для всех генераторов случайности (random, numpy, torch, torch.cuda.manual_seed_all) с включением cudnn.deterministic, что делает разбиение воспроизводимым бит-в-бит.

Распределение классов по сплитам (проверено независимым пересчётом при воспроизведении): обучающая выборка — 5760 снимков (COVID 2884 / Normal 2876), валидационная — 720 (355 / 365), тестовая — 720 (361 / 359). Все сплиты эмпирически сбалансированы: отношение классов в тесте составляет 1.006, что делает выбранную основную метрику (Accuracy) корректной и не смещённой к мажоритарному классу.

Ограничения схемы разбиения. Во-первых, random_split не выполняет стратификацию по классам: баланс достигнут эмпирически, а не гарантирован процедурой разбиения; фиксация seed устраняет неоднозначность для данного цикла, а вопрос стратификации будет пересмотрен в ПР1. Во-вторых, метаданные набора не содержат идентификаторов пациентов, поэтому patient-level разбиение (разделение по субъектам, предотвращающее утечку между сплитами) непостроимо; это ограничение зафиксировано и будет количественно оценено в ПР1 через анализ дубликатов и межсплитовых совпадений.

Сплит	Всего	COVID	Normal
train	5760	2884	2876
validation	720	355	365
test	720	361	359
Итого	7200	3600	3600

6. Архитектура модели и обучение baseline

Архитектура — ResNet18 (torchvision.models.resnet18) в режиме transfer learning: при обучении загружались предобученные веса ImageNet (IMAGENET1K_V1), замораживались все параметры, кроме блока layer4 (дообучение под медицинский домен) и новой классификационной головы fc = Sequential(Dropout(p=0.5), Linear(512, 2)). Инициализация — предобученные веса ImageNet; голова инициализируется стандартным образом. Общее число параметров — 11 177 538. Выбор ResNet18 обоснован распространённостью архитектуры в медицинской визуализации, умеренным размером (совместимым с учебным вычислительным бюджетом) и наличием предобученных весов.

Обучение: оптимизатор Adam (learning rate 1e-4, weight_decay 1e-5) по параметрам, требующим градиента; планировщик ReduceLROnPlateau(mode='max', factor=0.5, patience=3, min_lr=1e-7) по валидационной точности; функция потерь — CrossEntropyLoss; 20 эпох, batch size 32; ранняя остановка с patience=5 (фактически выполнены все 20 эпох без срабатывания улучшений; лучшая эпоха — 15, валидационная точность 0,9917; чекпойнт сохранялся по лучшей валидационной точности). Аугментации применялись только к обучающей выборке: RandomHorizontalFlip(p=0.5), RandomRotation(10°), ColorJitter(brightness=0.2, contrast=0.2) после Resize(224, 224).

Аппаратура и фиксация: обучение выполнено в Google Colab на GPU NVIDIA Tesla T4 (15.8 ГБ) под PyTorch 2.9.0+cu126, дата — 08.02.2026 (метаданные training_history.json); длительность обучения в исходных артефактах не фиксировалась (см. раздел 11). Модель сохранена как best_model.pth — PyTorch state_dict (122 тензора, ~44,8 МБ), загружается функцией torch.load(map_location='cpu') и reconstruct'ится архитектурой common.build_model(). В соответствии с завершающим правилом раздела 1 методики, baseline заморожен: во всех ПР1–ПР4 модель используется без изменения параметров, что обеспечивает сопоставимость результатов всего цикла.

Параметр	Значение
Архитектура	ResNet18 (transfer learning, ImageNet IMAGENET1K_V1)
Заморозка	все слои заморожены, кроме layer4 и головы fc
Голова	Dropout(0.5) + Linear(512 → 2)
Оптимизатор	Adam, lr = 1e-4, weight_decay = 1e-5
Планировщик	ReduceLROnPlateau(mode=max, factor=0.5, patience=3, min_lr=1e-7)
Эпохи / batch	20 / 32 (ранний останов patience=5; фактически — все 20)
Лучшая эпоха	15 (val accuracy 0,9917)
Аугментации	RandomHorizontalFlip(0.5), RandomRotation(10°), ColorJitter(0.2, 0.2)
Аппаратура обучения	Google Colab, NVIDIA Tesla T4 (15,8 ГБ), PyTorch 2.9.0+cu126
Дата обучения	2026-02-08 (training_history.json metadata)
Чекпойнт	best_model.pth — PyTorch state_dict, 122 тензора, ≈44,8 МБ

7. Основная метрика качества и её обоснование

Основная метрика качества — Accuracy (доля верных предсказаний на тестовой выборке). Согласно таблице §1.2 методических рекомендаций, для задач классификации допустимыми основными метриками являются Accuracy, Balanced Accuracy, Macro-F1 и ROC-AUC. Выбор Accuracy обоснован предметной областью и структурой данных: тестовый набор практически сбалансирован (361 COVID / 359 Normal, отношение классов 1.006, классовая энтропия близка к максимуму), поэтому Accuracy не смещена к мажоритарному классу и клинически интерпретируема как доля правильных решений скрининга.

Способ вычисления: для каждого объекта тестовой выборки сравниваются argmax логитов модели и истинная метка (эквивалент sklearn.metrics.accuracy_score); класс COVID считается положительным (индекс 0). Наряду с основной метрикой для полноты вычисляются вторичные метрики по классу COVID (recall, precision, F1), однако они не заменяют основную и приводятся с доверительными интервалами. Для Accuracy как доли событий используется 95%-й интервал Уилсона (§1.3; boot.pdf); для нелинейных вторичных метрик — percentile/bootstrap (B = 2000).

Согласованность использования: Accuracy фиксируется как основная метрика для всех четырёх практических работ цикла — в ПР2 она вычисляется на искажённых данных R(s) и входит в R-AUC, в ПР3 используется как robust accuracy, в ПР4 определяет генерализационный разрыв. Тем самым результаты всех работ сопоставимы между собой и с точкой отсчёта M(0).

8. Baseline-результат и 95% доверительный интервал

На неизменённом тестовом наборе (n = 720: 361 COVID / 359 Normal) замороженный чекпойнт best_model.pth показывает M(0) = 0,9833 с 95%-м доверительным интервалом Уилсона [0,9711; 0,9904]. Матрица ошибок: TP = 354, FN = 7, FP = 5, TN = 354 (сумма = 720). Интервал построен по правилу §1.3 для доли событий; ширина интервала отражает размер тестовой выборки (720 снимков).

Результат в точности совпадает с фиксацией исходного обучения: training_history.json содержит test_accuracy = 0,98333, recall(COVID) = 0,98061, precision(COVID) = 0,98607, F1(COVID) = 0,98333. Воспроизведение выполнено локально на другом оборудовании (NVIDIA GeForce RTX 2050, PyTorch 2.9.1+cu130) по сравнению с обучением (Google Colab, Tesla T4, PyTorch 2.9.0+cu126); совпадение метрики с точностью до машинного представления подтверждает корректность воспроизведённого пайплайна предобработки и разбиения, а также устойчивость инференса к смене окружения.

Вторичные метрики на тесте с 95% доверительными интервалами: recall(COVID) = 0.9806 [0.9605; 0.9906] (интервал Уилсона); precision(COVID) = 0.9861 [0.9678; 0.9940] (интервал Уилсона); F1(COVID) = 0.9833 [0.9727; 0.9918] (percentile bootstrap, B = 2000). Артефакты воспроизведения: results/baseline_eval.json (полная матрица ошибок, интервалы, список тестовых файлов) и ячейка baseline в PR1.ipynb, которая печатает то же значение M(0) и сверяет его с reproducibility.json. Эти результаты относятся к предварительному этапу; результаты ПР1–ПР4 в настоящий отчёт не входят.

Метрика	Значение	95% ДИ	Метод интервала
Accuracy (M(0))	0.9833	[0.9711; 0.9904]	Уилсон
Recall (COVID)	0.9806	[0.9605; 0.9906]	Уилсон
Precision (COVID)	0.9861	[0.9678; 0.9940]	Уилсон
F1 (COVID)	0.9833	[0.9727; 0.9918]	bootstrap B=2000

Матрица ошибок	Значение
TP (COVID верно)	354
FN (пропуск COVID)	7
FP (ложная тревога)	5
TN (Normal верно)	354

9. Воспроизводимость

Все семь пунктов §1.1 методики зафиксированы в файле reproducibility.json. (1) Версия и источник данных: Kaggle COVID-19 Radiography Database v4 + зеркало junelsolis/covid-19-radiography-dataset с проверенным совпадением счётчиков файлов по классам. (2) Схема разбиения: random_split 80/10/10 (seed 42) с распределением классов по сплитам (5760: 2884/2876; 720: 355/365; 720: 361/359). (3) Случайный seed: 42 — для random, numpy, torch

и CUDA, с cudnn.deterministic. (4) Архитектура и инициализация: ResNet18, transfer learning с ImageNet-инициализацией, заморожены все слои кроме layer4 и головы; при воспроизведении веса загружаются из best_model.pth. (5) Гиперпараметры обучения: Adam(1e-4, wd 1e-5), ReduceLROnPlateau(max, 0.5, patience 3, min_lr 1e-7), 20 эпох, batch 32, ранний останов patience 5, аугментации train-only. (6) Версии ключевых библиотек: 15 позиций (torch 2.9.1+cu130, torchvision 0.24.1+cu130, numpy 2.3.3, scipy 1.16.2, scikit-learn 1.7.2, pandas 2.3.3, Pillow 11.3.0 и др.). (7) Основная метрика и способ вычисления: Accuracy + описание процедуры (argmax против метки) и интервала Уилсона.

Файлы воспроизводимости: reproducibility.json (полный фиксатор параметров, включая среду обучения и детали разбиения); requirements.txt (приложение) и requirements_pr_cycle.txt (практический цикл, pinned-версии дополнительных библиотек); eval_baseline.py — самостоятельный программа точного воспроизведения M(0) на замороженном чекпойнте (результат — results/baseline_eval.json); ячейка baseline в PR1.ipynb дополнительно сверяет печатаемое значение M(0) с reproducibility.json. Среда инференса (Windows, NVIDIA RTX 2050, CUDA) отлична от среды обучения (Colab, Tesla T4), однако точное совпадение метрики демонстрирует переносимость пайплайна инференса.

10. План следующих работ (ПР1–ПР4)

В соответствии с разделом 1 методики и завершающим правилом («базовая модель должна использоваться во всех четырех практических работах без изменения ее параметров»), замороженный чекпойнт best_model.pth и зафиксированная метрика M(0) = 0,9833 [0,9711; 0,9904] будут использоваться без изменений во всех четырёх практических работах цикла.

План работ: ПР1 — исследование качества набора данных (полнота, валидность, уникальность/дубликаты, утечки train↔test, баланс, качество разметки, репрезентативность распределений, аномалии изображений); ПР2 — устойчивость baseline к естественным искажениям (шум, размытие, JPEG; кривые устойчивости R(s) и интегральная метрика R-AUC); ПР3 — состязательная устойчивость в постановке белого ящика (FGSM, PGD; ASR и R-AUC_ε; контроль независимой сильной атакой); ПР4 — приватность обучающей выборки (Membership Inference Attack; ROC-AUC, Attack Accuracy, TPR@FPR, генерализационный разрыв).

Настоящий отчёт содержит исключительно предварительный этап: результаты, таблицы, рисунки и выводы ПР1–ПР4 в него сознательно не включены и будут представлены отдельно по мере выполнения соответствующих работ. Замороженный baseline обеспечивает сопоставимость всех последующих экспериментов с зафиксированной точкой отсчёта M(0).

11. Ограничения предварительного этапа

Ограничения, зафиксированные на предварительном этапе (часть из них будет количественно исследована в последующих работах):

- Patient-level разбиение непостроимо: метаданные набора содержат только имя файла, формат, размер и URL, идентификаторов пациентов нет; следовательно, разделение сплитов по субъектам (предотвращение внутрипациентной утечки) невозможно. Риск будет количественно оценён в ПР1 через анализ дубликатов и межсплитовых совпадений снимков.
- random_split выполняется без стратификации по классам: сбалансированность сплитов достигнута эмпирически, а не гарантирована процедурой. Фиксация seed 42 устраняет неоднозначность для данного цикла; альтернативные схемы (стратифицированное разбиение) рассматриваются как возможное улучшение, но в рамках цикла не применяются, чтобы сохранить точную воспроизводимость baseline.
- Kaggle-датасет является «живым» (может обновляться на платформе): версия v4 зафиксирована через совпадение счётчиков файлов с зеркалом junelsolis/covid-19-radiography-dataset, поскольку Kaggle API локально недоступен. При изменении набора на платформе воспроизведение опирается на зеркало.
- Организованный пул — подвыборка v4: по правилу organize_dataset(max_per_class=3600) взяты первые 3600 отсортированных файлов каждого класса (из 3616 COVID и 10192 Normal); все результаты цикла относятся к этой подвыборке из 7200 снимков.
- Длительность обучения и полная среда выполнения (версии драйверов, точная конфигурация Colab) в исходных артефактах не зафиксированы; известны дата, GPU и версия PyTorch (метаданные training_history.json).
- Файл лицензии датасета в репозитории отсутствует: лицензия зафиксирована по странице Kaggle-набора («Data files © Original Authors») и описана в dataset_source.md, однако явных условий перераспространения она не задаёт.
- Полутоновые снимки конвертируются в трёхканальный RGB-вход — избыточность входа, унаследованная от предобученной архитектуры ImageNet; это не влияет на корректность, но увеличивает вычисления примерно втрое по каналам первого свёрточного слоя.
- Обучение и воспроизведение выполнены в разных средах (PyTorch 2.9.0+cu126 / Tesla T4 против PyTorch 2.9.1+cu130 / RTX 2050); точное совпадение M(0) подтверждает эквивалентность инференса на уровне метрики, однако побитовая идентичность отдельных логитов не гарантируется.