МИНОБРНАУКИ РОССИИ
Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)
Кафедра ИС

отчет
по практической работе
по дисциплине «Безопасность искусственного интеллекта»
Тема: Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки:
практическая работа №1 — исследование качества набора данных

Студенты гр. 1378 Панов А.Ю., Ханна М.Н., Семенов М.Д.
Преподаватель Новикова Е.С.

Санкт-Петербург
2026

ЗАДАНИЕ

Цель работы: приобретение навыков аудита доверенности систем искусственного интеллекта на примере медицинской системы диагностики COVID-19 по рентгенограммам грудной клетки; построение количественного профиля качества набора данных, который используется замороженной базовой моделью во всех практических работах цикла.

Исходная постановка задачи: бинарная классификация фронтальной рентгенограммы грудной клетки по признаку COVID-19 — класс «COVID» (положительный) против класса «Normal» (здоровый); решение принимается по одному изображению, без использования метаданных пациента. В практической работе №1 требуется описать набор данных и схему разбиения, количественно оценить восемь характеристик качества по §2.2 методических рекомендаций, проверить различие распределений train и test статистическими методами и зафиксировать свойства данных, потенциально влияющие на последующие эксперименты по робастности и приватности.

Качество набора данных рассматривается как многомерное свойство, а не как одна интегральная метрика: §2.1 прямо указывает, что сводить качество к одному числу не требуется, поскольку разные дефекты влияют на разные последующие эксперименты — устойчивость к естественным искажениям, состязательную устойчивость и приватность. Поэтому профиль ПР1 строится из восьми независимо измеряемых компонент: полнота, валидность, уникальность, утечка train↔test, баланс, качество разметки, репрезентативность и аномалии. Доли сопровождаются 95 %-м интервалом Уилсона, средние — bootstrap-интервалом, различие распределений — перестановочным тестом MMD и тестом C2ST.

Известные параметры:

Таблица 1. Исходные параметры системы и практической работы №1

Параметр	Значение
Аналитическая задача	бинарная классификация: COVID (положительный) / Normal (здоровый)
Набор данных	COVID-19 Radiography Database, v4 (зеркало для воспроизведения)
Пул и разбиение	7200 снимков (3600 / 3600); 80/10/10, seed 42 → 5760 / 720 / 720
Вход / выход	RGB-изображение 224×224×3 → 2 логита → вероятности классов
Архитектура	ResNet-18 (ImageNet), layer4 + fc; 11 177 538 параметров
Обучение	Adam, lr $1\cdot10^{-4}$, weight decay $1\cdot10^{-5}$, 20 эпох, batch 32
Основная метрика	Accuracy, M(0) = 0,9833 ★; 95 % ДИ [0,9711; 0,9904]
Артефакт и SHA-256	best_model.pth, 44 789 835 Б; 0ba793cb…b504f0
Инструменты ПР1	cleanlab 2.9.0, imagehash 4.3.2, pyiqa 0.1.16, OpenCV 5.0.0.93

Методическая рамка: §2.1–2.6; ДИ — §1.3 и boot.pdf; переобучение не выполняется.

ХОД РАБОТЫ

1. Постановка задачи и замороженная модель

Предметная область — медицинская визуализация: автоматический анализ фронтальных рентгенограмм грудной клетки по одному снимку, без метаданных пациента. Контекст применения — вспомогательная сортировка (triage): модель помечает снимки, окончательное решение принимает клиницист. Пропуск случая (FN) задерживает лечение, ложная тревога (FP) ведёт к необоснованной изоляции, поэтому качество модели рассматривается как вопрос безопасности.

Замороженный классификатор — ResNet-18 в режиме transfer learning: предобученные веса ImageNet, дообучение блока layer4 и головы Dropout(0,5) + Linear(512, 2); всего 11 177 538 параметров. Модель отображает изображение 224×224×3 в два логита (COVID, Normal), которые нормируются softmax в вероятности классов; ответ — класс с максимальной вероятностью, качество на неизменённом тесте — доля верных ответов M(0). Обучение: 20 эпох, Adam, lr $1 \cdot 10^{-4}$, batch 32; чекпойнт сохранён по лучшей валидационной точности (эпоха 15, 0,9917).

Файл best_model.pth (44 789 835 Б, SHA-256 0ba793cb43d0f058af66673a1026e6eef4bd898d98cae05eaf6694cb20b504f0) в ПР1 только загружается: параметры не обновляются, повторное обучение не выполняется, что обеспечивает сопоставимость со всеми работами цикла.

Таблица 2. Матрица ошибок на тестовой выборке (n = 720)

Истина / прогноз	COVID	Normal
COVID	354 (TP)	7 (FN)
Normal	5 (FP)	354 (TN)

В таблице зелёным выделены корректные классификации (TP, TN), красным — критические ошибки пропуска (FN), оранжевым — ложные тревоги (FP).

На 720 объектах теста получены TP = 354, FN = 7, FP = 5, TN = 354: 7 пропусков и 5 ложных тревог. Значение M(0) = 0,9833 ★ с 95 %-м интервалом Уилсона [0,9711; 0,9904] принимается в качестве точки отсчёта цикла. Наиболее критичной остаётся доля пропущенных случаев COVID, поэтому recall класса COVID интерпретируется отдельно от общей точности.

2. Набор данных и схема разбиения

Источник данных — открытый набор COVID-19 Radiography Database (версия v4). Полная версия содержит 3616 снимков класса COVID и 10192

снимка класса Normal; для бинарной задачи используется сбалансированная подвыборка из 3600 отсортированных файлов каждого класса. Локальный доступ к API платформы недоступен, поэтому применено зеркало набора с проверенным совпадением счётчиков файлов по классам.

Лицензия — «Data files © Original Authors»: явная открытая лицензия для перераспределения не заявлена, поэтому файлы в артефакты цикла не включаются (dataset_source.md).

Таблица 3. Состав используемого набора данных

Класс	Снимков в версии v4	Использовано в цикле	Доля в пуле
COVID	3616	3600	50,0 %
Normal	10192	3600	50,0 %
Итого	13 808	7200	100 %

Разбиение выполнено в пропорции 80/10/10 с seed 42: обучающая выборка — 5760 снимков, валидационная — 720, тестовая — 720 (361 COVID / 359 Normal). Классы сортируются по алфавиту (COVID = 0, Normal = 1), после чего применяется случайное разбиение без стратификации; баланс достигнут эмпирически.

Таблица 4. Распределение классов по выборкам

Выборка	Всего	COVID	Normal	Доля
Обучающая	5760	2884	2876	80 %
Валидационная	720	355	365	10 %
Тестовая	720	361	359	10 %

Пайплайн инференса: Resize((224, 224)) → ToTensor() → Normalize по статистикам ImageNet; полутоновой снимок конвертируется в трёхканальный вид. Аугментации (отражение, поворот 10°, яркость и контраст 0,2) применяются только к обучающей выборке, поэтому профиль относится к неизменённым данным. Метаданные не содержат идентификаторов пациентов, поэтому разбиение по субъектам непостроимо; это ограничение оценивается в §4.3.

3. Методика количественной оценки

Аудит следует §2.2 методических рекомендаций: для каждой из восьми характеристик вычисляется отдельная оценка, а итог сводится в таблицу по §2.5. Доли сопровождаются 95 %-м интервалом Уилсона (z = 1,95996) — он

корректен при значениях, близких к 0 и 1, где нормальная аппроксимация даёт пустые или выходящие за границы интервалы.

Средние значения NIQE и BRISQUE сопровождаются перцентильным bootstrap-интервалом (B = 2000, seed 42); перевыбираются только объекты, модель не переобучается. Различие распределений train и test проверяется двумя способами: MMD^2 на эмбеддингах предпоследнего слоя с перестановочным p-значением (200 перестановок) и C2ST по AUC классификатора train/test. Счётчики дубликатов и утечек точны, интервалы описывают перенос оценки на более общую совокупность; все характеристики измеряются на одном пуле и разбиении с одним чекпойнтом.

4. Результаты исследования качества данных

4.1. Полнота и валидность

Полнота характеризует долю объектов, которые отсутствуют в наборе или не могут быть прочитаны. Проверены все 7200 файлов пула: контролировались наличие, успешное открытие и чтение декодером; пропущенных и нечитаемых — 0 из 7200. Валидность проверяет соответствие файлов формату, диапазону значений и ограничениям предметной области: тип файла, число каналов, диапазон пикселей и минимальный размер. Нарушений не обнаружено, все файлы полутоновые (100 % grayscale), короткая сторона не менее 128 пикселей.

Таблица 5. Полнота и валидность набора данных

Характеристика	Проверка	Результат	95 % ДИ
Полнота	пропущенные / нечитаемые файлы	0 из 7200	[0,0000; 0,0005]
Полнота	доля пропусков	0,0000 %	[0,0000; 0,0005]
Валидность	нарушения формата / диапазона	0 %	[0,0000; 0,0005]
Валидность	grayscale	100 %	—
Валидность	короткая сторона < 128 px	0 %	[0,0000; 0,0005]

Доля пропусков — 0,0000 %, 95 %-й интервал Уилсона [0,0000; 0,0005]; верхняя граница показывает, какую долю пропусков ещё совместимо с наблюдёнными данными. Валидность формата не гарантирует клиническую валидность разметки (§4.5).

4.2. Уникальность

Уникальность оценивается по двум независимым критериям. Точные дубликаты ищутся по MD5-хешу: совпадение хеша означает побайтовое тождество. Близкие дубликаты ищутся по перцептивному хешу: кандидаты с

расстоянием Хэмминга phash ≤ 6 дополнительно проверяются попиксельно и принимаются только при среднем абсолютном различии ≤ 10, что снижает число ложных срабатываний.

Таблица 6. Точные и близкие дубликаты

Тип	Критерий	Файлов	Доля от 7200	Групп	95 % ДИ
Точные	совпадение MD5	46	0,6389 %	34	[0,0048; 0,0085]
Близкие	phash ≤ 6 и mean|diff| ≤ 10	262	3,6389 %	199	[0,0323; 0,0410]
Структурно схожие	phash ≤ 6, пиксельно различны	1930 пар	26,81 %	—	[0,2579; 0,2784]

Структурно схожие пары проходят фильтр phash ≤ 6, но отклоняются по попиксельной проверке и дубликатами не считаются.

Точных дубликатов 46 из 7200 (0,6389 %, 34 группы), близких — 262 из 7200 (3,6389 %, 199 кластеров): точный уровень низкий, близкий — умеренный. Отдельно выделены 1930 «структурно схожих» пар (phash ≤ 6, но визуально различимых) — 26,81 % от пула; они дубликатами не считаются. Близкие дубликаты не являются побайтовыми копиями, поэтому их влияние на тест зависит от попадания пары в разные части разбиения (§4.3); дубликаты не удалялись, поскольку профиль фиксирует свойство набора, а не очистку.

4.3. Утечка train↔test

Утечка оценивается как число пар объектов, совпадающих или почти совпадающих между обучающей и тестовой выборками: точные пары определяются по MD5, близкие — по схеме phash + попиксельная проверка. Обнаружено 7 точных и 64 близких пары. Это файловая утечка: у части тестовых снимков есть почти идентичный «двойник» в обучении, что не доказывает совпадения пациентов, но означает частичное пересечение данных.

Таблица 7. Утечка train↔test

Тип пары	Число пар	Комментарий
Точные	7	совпадение MD5 между train и test
Близкие	64	phash ≤ 6 + попиксельная проверка

Красным выделены точные совпадения, оранжевым — близкие пары; цвет указывает на риск утечки, а не на клиническую ошибку.

Разбиение по пациентам невозможно: метаданные не содержат идентификаторов. Поэтому перцептивный хеш — наиболее сильный

доступный прокси-критерий утечки, что соответствует G-2 («устранено в доступной форме»). Полученные 7 + 64 пары — реальная файловая утечка, а не артефакт метрики; её влияние на метрики в ПР1 не измеряется и передаётся в интерпретацию ПР2–ПР4.

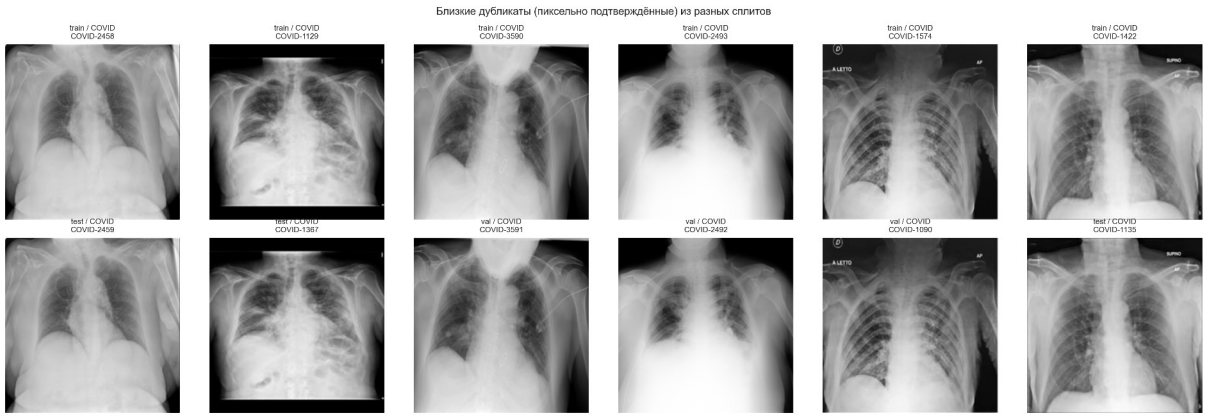


Рис. 1. Примеры близких дубликатов (пиксельно подтверждённых) из разных сплитов — почти идентичные снимки одновременно в обучении и оценке.

4.4. Баланс

Баланс описывает распределение классов и форму этого распределения. В тестовой выборке 361 снимок COVID и 359 снимков Normal: imbalance ratio равен 0,9945, классовая энтропия — 0,6931 нат при максимуме $\ln 2 \approx 0{,}6931$, то есть баланс практически полный. Он достигнут эмпирически, а не стратификацией: отклонение составляет 2 объекта.

Таблица 8. Баланс классов по выборкам

Показатель	Значение
COVID / Normal в тесте (n = 720)	361 / 359
Imbalance ratio (тест)	0,9945 ★
Классовая энтропия (тест)	0,6931 нат (максимум ln 2)
COVID / Normal в train (n = 5760)	2884 / 2876
COVID / Normal в val (n = 720)	355 / 365

Поскольку дисбаланс отсутствует, Accuracy не смещена к мажоритарному классу и остаётся основной метрикой. Баланс не отменяет других дефектов: дубликаты и утечка анализируются отдельно.

4.5. Качество разметки

Качество разметки оценивается методом Confident Learning (cleanlab 2.9.0) на out-of-sample вероятностях, полученных при 5-кратной кросс-

валидации; это снижает оптимистическое смещение, возникающее при использовании предсказаний на тех же объектах, где обучалась модель. Для train найдено 0 ошибок из 5760 (0 %), для test — 3 ошибки из 720 (0,4167 %). Объекты с наименьшим label quality выгружены в label_inspection.csv и просмотрены вручную.

Таблица 9. Качество разметки (Confident Learning)

Выборка	Объектов	Ошибок	Доля	95 % ДИ
Train	5760	0	0 %	—
Test	720	3	0,4167 %	[0,0014; 0,0122]

Доля ошибок на тесте — 0,4167 % с 95 %-м интервалом [0,0014; 0,0122]. Три объекта могут изменить счётчик ошибок baseline, поэтому вывод условный: шум меток низкий, но не нулевой. Ручная проверка служит контролем наиболее подозрительных случаев, но не заменяет полный аудит 7200 объектов.

4.6. Репрезентативность

Репрезентативность проверяется двумя независимыми способами. Первый — MMD^2 на эмбеддингах предпоследнего слоя замороженного ResNet-18 с RBF-ядром и шириной по медианной эвристике: статистика сравнивает средние значения ядра внутри каждой выборки и между ними и при совпадении распределений близка к нулю. Второй — C2ST: бинарный классификатор, обучаемый отличать train от test по тем же эмбеддингам; при совпадении распределений его AUC близок к 0,5.

Наблюдаемая статистика $MMD^2 = -0{,}000392$, перестановочное p-значение = 0,705 (200 перестановок, seed 42). Поскольку $p > 0{,}05$, нулевая гипотеза о совпадении распределений не отвергается; отрицательное конечновыборочное значение MMD^2 не является «отрицательным расстоянием». C2ST даёт AUC = 0,4885 с 95 %-м интервалом [0,4640; 0,5139]: интервал содержит 0,5, что соответствует случайному уровню.

Таблица 10. Проверка различия распределений train/test

Тест	Статистика	Значение	95 % ДИ / p	Вывод
MMD^2	RBF, median heuristic	−0,000392	p = 0,705	сдвиг не обнаружен
C2ST	AUC	0,4885	[0,4640; 0,5139]	случайный уровень
C2ST	CV-точность (5-fold)	0,5923	[0,5718; 0,6126]	согласуется с AUC

CV-точность 0,5923 сопровождается balanced accuracy 0,5037 и AUC 0,4885: совместно эти показатели не дают согласованного свидетельства сдвига.

Оба теста согласованы: MMD не отвергает нулевую гипотезу, C2ST не отличает train от test. Следовательно, сдвиг распределений в ПР1 не обнаружен и тестовая выборка сопоставима с обучающей. Пятикратная CV-точность C2ST равна 0,5923 [0,5718; 0,6126], однако balanced accuracy составляет 0,5037, а AUC — 0,4885, поэтому эти показатели не дают согласованного свидетельства сдвига. Формальные тесты по подгруппам не заявляются; по классам сопоставлены только средние NIQE и BRISQUE (§4.7).

4.7. Аномалии

Аномалии описываются тремя взаимодополняющими критериями: NIQE-выбросы (верхний хвост распределения no-reference качества), чрезмерное размытие (низкая дисперсия лапласиана) и коллимационные чёрные рамки (тёмный кант по краю кадра). Доля NIQE-выбросов составляет 2,22 %, доля чрезмерно размытых изображений — 2,50 %, доля снимков с чёрной рамкой (класс Normal) — 0,69 %. Все значения низкие, но NIQE-оценка имеет широкий интервал, поэтому точечное значение 2,22 % не следует трактовать как точную долю во всей генеральной совокупности.

Таблица 11. Аномалии и средние значения no-reference метрик

Показатель	Значение	95 % ДИ
Доля NIQE-выбросов (верхний хвост)	2,22 %	[0,0061; 0,0774]
Доля чрезмерно размытых (дисперсия лапласиана)	2,50 %	[0,0216; 0,0289]
Доля снимков с чёрной рамкой (Normal)	0,69 %	[0,0047; 0,0102]
NIQE, среднее: COVID / Normal	6,52 / 5,91	[6,31; 6,76] / [5,80; 6,02]
BRISQUE, среднее: COVID / Normal	29,06 / 29,73	не вычислялся

Доверительные интервалы пересчитаны из фактических счётчиков аномалий (исправление C-1 аудита).

Аномалии не удалялись и не корректировались: профиль фиксирует их наличие. Широкий интервал для NIQE-выбросов отражает малое число событий и не позволяет утверждать, что доля аномалий стабильна в других совокупностях. Нетипичные снимки могут вносить вклад в ошибки, но их доля недостаточна для объяснения изменений устойчивости.

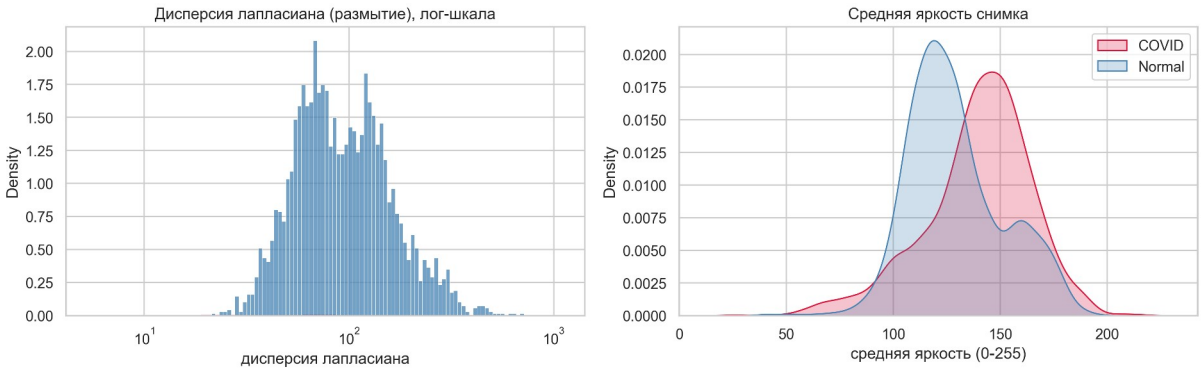


Рис. 2. Распределения яркости и резкости (лапласиан) — визуальный контроль артефактов качества.

5. Сводная таблица результатов (§2.5)

Сводная таблица фиксирует итог по всем восьми характеристикам в форме §2.5. Знак ★ отмечает благоприятный результат: отсутствие пропусков и нарушений, баланс классов, отсутствие обнаруженного сдвига.

Таблица 12. Сводная таблица результатов ПР1 (§2.5)

Свойство	Метрика	Значение	95 % ДИ	Интерпретация
Полнота	missing rate	0 / 7200 ★	[0,0000; 0,0005]	OK
Валидность	invalid rate	0 / 7200 ★	[0,0000; 0,0005]	OK
Дубликаты	exact dup rate (MD5)	0,6389 %	[0,48 %; 0,85 %]	низкий уровень
Дубликаты	near dup rate (phash+pixel)	3,6389 %	[3,23 %; 4,10 %]	умеренный уровень
Дубликаты	structurally similar (phash ≤ 6)	1930 (26,81 %)	[0,2579; 0,2784]	не дубликаты
Качество разметки	label error rate (test)	0,4167 % (3/720)	[0,14 %; 1,22 %]	низкий уровень
Баланс	imbalance ratio	0,9945 ★	—	сбалансирован
Сдвиг	MMD^2 / permutation p	−0,000392 / 0,705 ★	—	сдвиг не обнаружен
Сдвиг	C2ST AUC	0,4885 ★	[0,4640; 0,5139]	случайный уровень
Сдвиг	C2ST CV-точность	0,5923	[0,5718; 0,6126]	balanced acc. 0,5037
Утечка	exact + near train↔test	7 + 64	—	присутствует
Аномалии	NIQE-выбросы / размытие	2,22 % / 2,50 %	[0,61 %; 7,74 %] / [2,16 %; 2,89 %]	низкая доля
Аномалии	чёрная рамка (Normal)	0,69 %	[0,47 %; 1,02 %]	низкая доля

★ — *благоприятный результат; оранжевым выделена строка утечки, поскольку она требует учёта в последующих работах.*

Профиль не сводится к одному числу: полнота и валидность благоприятны, баланс и репрезентативность не вызывают тревоги, качество разметки низкое по доле ошибок, однако уникальность и утечка содержат реальные дефекты. Именно эти дефекты, а не средняя оценка, переносятся в интерпретацию ПР2–ПР4.

6. Устранение ограничений, воспроизводимость и план работ

Предварительный этап оставил три ограничения: G-1 — не зафиксирована длительность обучения; G-2 — отсутствуют идентификаторы пациентов, поэтому разбиение по пациентам непостроимо; G-3 — отсутствовал файл лицензии. В ПР1 для каждого ограничения указана конкретная мера и её статус.

Таблица 13. Устранение ограничений предварительного этапа

#	Ограничение	Мера ПР1	Статус
G-1	Training duration not recorded	Inference latency 14,70 ± 0,81 мс/снимок	частично устранено
G-2	Patient IDs missing → patient-level split unbuildable	Perceptual-hash leakage analysis: 7 exact + 64 near pairs	устранено в доступной форме
G-3	License file missing	Documented in dataset_source.md (V2)	полностью устранено

G-1: длительность обучения восстановить нельзя, поэтому вместо неё измерена стоимость инференса — 14,70 ± 0,81 мс на снимок (CPU, batch = 1, 100 изображений, 5 прогревочных прогонов). G-2: пациентские идентификаторы отсутствуют, поэтому перцептивный хеш остаётся наиболее сильным доступным прокси и фиксирует 7 точных и 64 близких пары. G-3: лицензия задокументирована в dataset_source.md (V2).

Воспроизводимость обеспечена seed 42 для всех генераторов с детерминированным режимом, B = 2000 для bootstrap и 200 перестановками для MMD; модель не переобучается — чекпойнт только загружается. Версии библиотек: cleanlab 2.9.0, imagehash 4.3.2, pyiqa 0.1.16, OpenCV 5.0.0.93, scikit-learn 1.7.2, scipy 1.16.2, torch 2.9.1+cu130.

Машиночитаемые артефакты — metrics_pr1.json, quality_profile.csv, label_inspection.csv, inference_latency.json.

План работ: ПР2 — устойчивость к естественным искажениям и R-AUC; ПР3 — состязательная устойчивость (white-box, ASR); ПР4 — membership inference и ROC-AUC; во всех работах используется тот же чекпойнт и то же разбиение.

ВЫВОДЫ

— Профиль качества построен как многомерный вектор из восьми характеристик; он не сводится к одной интегральной метрике.
— Полнота: 0 пропущенных и 0 нечитаемых файлов из 7200, 95 % ДИ [0,0000; 0,0005]; валидность: 0 % нарушений, 100 % grayscale, короткая сторона не менее 128 px.
— Точные дубликаты: 46 из 7200 = 0,6389 % [0,48 %; 0,85 %]; близкие: 262 из 7200 = 3,6389 % [3,23 %; 4,10 %].
— Утечка train↔test: 7 точных и 64 близких пары; пациентское разбиение непостроимо, поэтому перцептивный хеш — наиболее сильный доступный прокси (G-2).
— Баланс теста: 361 COVID / 359 Normal, imbalance ratio 0,9945, энтропия 0,6931 нат; Accuracy остаётся корректной основной метрикой.
— Качество разметки: train 0/5760 = 0 %, test 3/720 = 0,4167 % [0,14 %; 1,22 %]; шум низкий, но не нулевой.
— Сдвиг распределений не обнаружен: $MMD^2 = -0{,}000392$, $p = 0{,}705$; C2ST AUC = 0,4885 [0,4640; 0,5139].
— Аномалии: NIQE-выбросы 2,22 % [0,61 %; 7,74 %], чрезмерное размытие 2,50 % [2,16 %; 2,89 %]; средние NIQE 6,52 / 5,91, BRISQUE 29,06 / 29,73.
— Стоимость инференса — 14,70 ± 0,81 мс/снимок (CPU, batch = 1); это частично закрывает G-1, но не восстанавливает длительность обучения.
— Профиль качества не является свободным от дефектов: дубликаты и утечка зафиксированы количественно, а выводы ограничены выбранным набором, разбиением и статистической неопределённостью.

Обнаруженная файловая утечка train↔test (7 точных и 64 близких пары) влияет и на последующие этапы цикла. В ПР2 часть тестовых снимков имеет почти идентичного «двойника» в обучении, поэтому устойчивость к естественным искажениям на таких парах может быть слегка завышена. В ПР3 эти же «запомненные» примеры способны исказить оценку состязательной устойчивости: состязательное возмущение, подобранное для одного дубликата, может остаться неэффективным для его почти идентичной пары. В ПР4 наличие почти одинаковых снимков одновременно в train и test усиливает сигнал membership inference, из-за чего оценка приватности может оказаться пессимистичнее реальной. Направление и величина суммарного эффекта по каждой работе в ПР1 не измеряются и выносятся в интерпретацию ПР2–ПР4.

Рекомендуемая литература (§2.6)

1. Northcutt C. G., Jiang L., Chuang I. L. Confident Learning: Estimating Uncertainty in Dataset Labels. Journal of Artificial Intelligence Research, 70, 1373–1411, 2021. DOI: 10.1613/JAIR.1.12125.
2. Gretton A. et al. A Kernel Two-Sample Test. Journal of Machine Learning Research, 13, 723–773, 2012.
3. Mittal A., Moorthy A. K., Bovik A. C. No-Reference Image Quality Assessment in the Spatial Domain. IEEE Transactions on Image Processing, 2012.
4. Mittal A., Soundararajan R., Bovik A. C. Making a Completely Blind Image Quality Analyzer. IEEE Signal Processing Letters, 2013.
5. Lee K. et al. Deduplicating Training Data Makes Language Models Better. ACL, 2022.