МИНОБРНАУКИ РОССИИ
Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)
Кафедра ИС

отчет

по практической работе
по дисциплине «Безопасность искусственного интеллекта»

Тема: Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки: предварительный этап

Студенты гр. 1378 Панов А.Ю., Ханна М.Н., Семенов М.Д.
Преподаватель Новикова Е.С.

Санкт-Петербург
2026

ЗАДАНИЕ

Цель работы: приобретение навыков аудита доверенности систем искусственного интеллекта на примере медицинской системы диагностики COVID-19 по рентгенограммам грудной клетки; формирование воспроизводимой «точки отсчёта» (замороженная базовая модель и её метрика) для всего практического цикла.

Исходная постановка задачи: бинарная классификация фронтальной рентгенограммы грудной клетки по признаку COVID-19 — класс «COVID» (положительный) против класса «Normal» (здоровый); решение принимается по одному изображению, без использования метаданных пациента. Требуется выбрать и описать набор данных, определить входную и выходную модальности, сформировать обучающую, валидационную и тестовую выборки, выбрать архитектуру глубокой модели, обучить baseline-модель, определить основную метрику качества и зафиксировать все параметры вычислительного эксперимента для воспроизводимости.

Известные параметры:

Таблица 1. Исходные параметры предварительного этапа

Параметр	**Значение**
Аналитическая задача	бинарная классификация: COVID (положительный) / Normal
Набор данных	COVID-19 Radiography Database (v4)
Организованный пул	7200 снимков (3600 COVID / 3600 Normal)
Входная модальность	RGB-тензор 224×224×3
Выходная модальность	2 логита → softmax
Разбиение	80/10/10, seed 42 → 5760 / 720 / 720
Архитектура	ResNet18 (ImageNet), обучаемые layer4 + fc
Число параметров	11 177 538
Оптимизатор	Adam, lr $1\cdot10^{-4}$, weight decay $1\cdot10^{-5}$
Эпохи / батч	20 / 32
Основная метрика	Accuracy, M(0)
Значение M(0)	0,9833; 95 % ДИ Уилсона [0,9711; 0,9904]
Артефакт модели	best_model.pth (44 789 835 Б)

Дата сдачи работы на проверку: 27.10.2026

ТЕОРИЯ

Доверенность (trustworthiness) системы искусственного интеллекта — интегральная характеристика, складывающаяся из нескольких измеримых свойств: качества данных, устойчивости к естественным искажениям, состязательной устойчивости, приватности обучающей выборки и интерпретируемости решений. Формально вектор доверенности задаётся как упорядоченный набор свойств:

$$\mathcal{T} = (Q,\ R_{\text{rob}},\ R_{\text{adv}},\ \text{П},\ \mathcal{I})$$

где:

- Q — качество данных (полнота, валидность, уникальность, сбалансированность);
- R_{rob} — устойчивость к естественным искажениям входов;
- R_{adv} — состязательная (adversarial) устойчивость;
- П — приватность обучающей выборки;
- $\mathcal{I}$ — интерпретируемость решений.

Оценка доверенности требует не одного числа, а согласованного набора измерений на одном и том же объекте исследования. Настоящий практический цикл построен именно по такому принципу: единый набор данных и единая замороженная модель последовательно исследуются по каждому из свойств доверенности.

Асимметрия последствий ошибок в медицинском скрининге формализуется функционалом ожидаемых потерь:

$$\mathcal{R}(\theta) = c_{FN}\, FN(\theta) + c_{FP}\, FP(\theta), \qquad c_{FN} \gg c_{FP} > 0$$

где:

- $\mathcal{R}(\theta)$ — ожидаемые потери решающего правила при параметрах θ;
- $FN(\theta)$ — число пропусков (ложноотрицательных решений) на выборке;
- $FP(\theta)$ — число ложных тревог (ложноположительных решений);
- $c_{FN},\ c_{FP}$ — стоимости ошибок пропуска и ложной тревоги (положительные константы; в работе задаются качественно, $c_{FN} \gg c_{FP}$).

Асимметрия стоимостей ошибок превращает качество модели из чисто технической характеристики в вопрос безопасности: пропуск случая задерживает лечение и способствует распространению инфекции, тогда как ложная тревога ведёт к необоснованной изоляции и лишнему дообследованию.

В качестве точки отсчёта цикла фиксируется базовая (baseline) модель и её метрика качества на неизменённом тестовом наборе. Согласно завершающему правилу методических рекомендаций, базовая модель должна использоваться во всех практических работах без изменения её параметров: любое дообучение или замена весов сделали бы результаты несопоставимыми. Поэтому предварительный этап завершается замораживанием чекпойнта и полной фиксацией параметров эксперимента.

Статистические границы результата задаются теорией биномиальных пропорций: для доли верных решений применяется интервал Уилсона, корректно работающий на границах и при умеренных объёмах выборки, а для нелинейных вторичных метрик — перцентильный бутстрэп. Оба аппарата и их параметры формализованы в разделе 4.

ХОД РАБОТЫ

1. Математическая постановка задачи

1.1. Пространства и отображение модели

Входом классификатора является изображение, представленное тензором фиксированного размера; выходом — вектор логитов для двух классов. Нейросетевое отображение задаётся как

$$\mathcal{X} \subset \mathbb{R}^{224\times224\times3}, \qquad f_\theta : \mathcal{X} \to \mathbb{R}^2, \qquad \mathbf{x} \mapsto f_\theta(\mathbf{x}).$$

где:

- $\mathcal{X}$ — пространство входных изображений после предобработки (тензор 224×224×3);
- $\mathbf{x} \in \mathcal{X}$ — отдельное изображение;
- f_θ — нейросетевой классификатор (ResNet18 с заменённой головой);
- $\theta \in \mathbb{R}^P$ — вектор обучаемых параметров, $P = 11\,177\,538$;
- $\mathbb{R}^2$ — пространство логитов для классов $\{0,1\}$.

1.2. Логиты и вероятностная интерпретация

Вектор логитов преобразуется в вероятности классов нормированной экспонентой (softmax):

$$\mathbf{z} = f_\theta(\mathbf{x}) = (z_0, z_1)^\top, \qquad P(y = c \mid \mathbf{x}; \theta) = \frac{e^{z_c}}{\sum_{k=0}^{1} e^{z_k}}.$$

где:

- $\mathbf{z} = (z_0, z_1)^\top$ — вектор логитов размерности 2;
- z_c — логит класса c;
- $P(y = c \mid \mathbf{x}; \theta)$ — апостериорная вероятность класса c при входе $\mathbf{x}$;
- $c \in \{0,1\}$ — индекс класса: 0 — COVID (положительный), 1 — Normal;
- k — индекс суммирования по классам.

1.3. Решающее правило

Итоговый ответ системы — класс с максимальной вероятностью, что эквивалентно классу с максимальным логитом:

$$\hat{y}_i = \arg\max_{c \in \{0,1\}} f_\theta(\mathbf{x}_i)_c, \qquad i = 1, \ldots, n.$$

где:

- $\hat{y}_i$ — прогноз модели для i-го снимка;
- $\mathbf{x}_i$ — i-е изображение тестовой выборки;
- $n = 720$ — объём тестовой выборки;
- argmax — выбор класса с наибольшим логитом.

2. Модель данных и структура распределения

2.1. Состав набора данных

Источник данных — открытый набор «COVID-19 Radiography Database» (версия v4), классы COVID и Normal. Полная версия v4 содержит 3616 снимков класса COVID и 10192 снимка класса Normal. Для бинарной задачи используется сбалансированная подвыборка: первые 3600 отсортированных файлов каждого класса копируются в плоскую ImageFolder-структуру, что снимает исходный дисбаланс и выравнивает классы. Поскольку локальный доступ к API платформы недоступен, для воспроизведения использовано зеркало набора, у которого число файлов по каждому классу точно совпадает с версией v4; тождество состава подтверждено попарным подсчётом файлов.

Таблица 2. Состав используемого набора данных

Класс	**Снимков в версии v4**	**Использовано в цикле**	**Доля в пуле**
COVID	3616	3600	50,0 %
Normal	10192	3600	50,0 %
Итого	13 808	7200	100 %

Лицензия набора, указанная на его странице, — «Data files © Original Authors»: файлы данных принадлежат авторам набора, явная открытая лицензия для перераспространения не заявлена; файлы данных в артефакты цикла не включаются.

2.2. Входная и выходная модальности

Входная модальность — RGB-изображение размера 224×224×3. Исходный снимок является полутоновым (grayscale) и конвертируется в трёхканальный вид (три одинаковых канала), после чего приводится к размеру 224×224 билинейной интерполяцией. Нормализация выполняется по статистикам ImageNet:

$$\tilde{\mathbf{x}} = \frac{\mathbf{x} - \mu}{\sigma}, \qquad \mu = (0{,}485;\ 0{,}456;\ 0{,}406)^{\top}, \qquad \sigma = (0{,}229;\ 0{,}224;\ 0{,}225)^{\top}.$$

где:

- $\tilde{\mathbf{x}}$ — нормализованный тензор, подаваемый на вход сети;
- $\mathbf{x}$ — тензор изображения после приведения к размеру 224×224 и перевода в шкалу $[0,1]$;
- μ — вектор средних значений по каналам ImageNet;
- σ — вектор стандартных отклонений по каналам ImageNet.

Выходная модальность — вектор логитов размерности 2, преобразуемый функцией softmax в вероятности $P(\text{COVID})$ и $P(\text{Normal})$; итоговый ответ — класс с максимальной вероятностью. Пайплайн предобработки инференса един во всех артефактах цикла, что является обязательным условием сопоставимости результатов.

2.3. Разбиение выборок

Схема разбиения воспроизводит исходный ноутбук: классы сортируются по алфавиту (COVID = 0, Normal = 1), после чего применяется случайное разбиение с фиксированным seed 42. Сумма объёмов выборок равна объёму пула:

$$n_{\text{train}} + n_{\text{val}} + n_{\text{test}} = n_{\text{pool}}, \qquad (n_{\text{train}}, n_{\text{val}}, n_{\text{test}}) = (5760,\ 720,\ 720).$$

где:

- $n_{\text{pool}} = 7200$ — объём организованного пула;
- $n_{\text{train}} = 5760$ — объём обучающей выборки (80 %);
- $n_{\text{val}} = 720$ — объём валидационной выборки (10 %);
- $n_{\text{test}} = 720$ — объём тестовой выборки (10 %);
- $\text{seed} = 42$ — фиксированное зерно генераторов случайности.

Таблица 3. Распределение классов по выборкам

Выборка	Всего	COVID	Normal	Доля
Обучающая	5760	2884	2876	80 %
Валидационная	720	355	365	10 %
Тестовая	720	361	359	10 %

Ограничения схемы: случайное разбиение не выполняет стратификацию по классам (баланс достигнут эмпирически, а не гарантирован процедурой), а метаданные набора не содержат идентификаторов пациентов, поэтому разбиение по субъектам непостроимо. Оба ограничения зафиксированы и будут количественно оценены на последующих этапах.

2.4. Предобработка и аугментации

Аугментации применяются исключительно к обучающей выборке: RandomHorizontalFlip($p = 0{,}5$), RandomRotation($10°$) и ColorJitter(brightness $= 0{,}2$, contrast $= 0{,}2$) после приведения к размеру 224×224. Валидационная и тестовая выборки не аугментируются, что обеспечивает корректность измерения метрики.

3. Архитектура нейросетевого классификатора

3.1. Архитектура

Архитектура — ResNet18 в режиме transfer learning. Все параметры замораживаются, кроме блока layer4 и новой классификационной головы; признаковый вектор размерности 512 отображается в два логита:

$$\mathbf{h} = g_{\phi}(\mathbf{x}) \in \mathbb{R}^{512}, \qquad f_{\theta}(\mathbf{x}) = W\,\mathrm{Dropout}_{0,5}(\mathbf{h}) + \mathbf{b}.$$

где:

- g_{ϕ} — свёрточный экстрактор ResNet18 без классификационной головы;
- $\mathbf{h}$ — признаковый вектор размерности 512;
- $\mathrm{Dropout}_{0,5}$ — регуляризация с вероятностью отключения 0,5;
- $W \in \mathbb{R}^{2\times 512}$ — матрица весов головы;
- $\mathbf{b} \in \mathbb{R}^{2}$ — вектор смещений головы.

Таблица 4. Архитектура и гиперпараметры обучения

Параметр	**Значение**
Архитектура	ResNet18
Инициализация	ImageNet (IMAGENET1K_V1)
Обучаемые блоки	layer4 + fc
Классификационная голова	Dropout(0,5) → Linear(512, 2)
Число параметров	11 177 538
Функция потерь	CrossEntropyLoss
Оптимизатор	Adam
Скорость обучения	$1 \cdot 10^{-4}$
Weight decay	$1 \cdot 10^{-5}$
Планировщик	ReduceLROnPlateau(max, factor 0,5, patience 3, min_lr $1 \cdot 10^{-7}$)
Число эпох	20 (лучшая — 15)
Размер батча	32
Ранняя остановка	patience 5
Размер входа	224×224

3.2. Процедура обучения

Обучение выполнено за 20 эпох; планировщик снижал скорость обучения по валидационной точности, ранняя остановка не сработала, чекпойнт сохранялся по лучшей валидационной точности (эпоха 15, значение 0,9917). Сохранённый чекпойнт — словарь состояния модели (122 тензора, 44 789 835 байт), загружаемый на CPU и восстанавливаемый заданной архитектурой. В соответствии с завершающим правилом методики базовая модель заморожена.

3.3. Среда выполнения

Таблица 5. Среда выполнения эксперимента

Компонент	**Обучение baseline**	**Воспроизведение**
Платформа	Google Colab	Windows (локально)
Графический ускоритель	NVIDIA Tesla T4 (15,8 ГБ)	NVIDIA GeForce RTX 2050
Версия PyTorch	2.9.0+cu126	2.9.1+cu130
Дата	08.02.2026	—
Значение M(0)	0,98333 (журнал обучения)	0,9833 [0,9711; 0,9904]

4. Математический аппарат валидации и доверительного оценивания

4.1. Основная метрика (Accuracy)

Основная метрика качества — доля верных предсказаний на тестовой выборке:

$$M(\theta) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\,(\hat{y}_i = y_i).$$

где:

- $M(\theta) \in [0,1]$ — основная метрика (Accuracy) при параметрах θ;
- $n = 720$ — объём тестовой выборки;
- $\hat{y}_i$ — прогноз модели для i-го снимка;
- $y_i \in \{0,1\}$ — истинная метка i-го снимка;
- $\mathbb{I}(\cdot)$ — индикатор истинности условия.

Выбор Accuracy обоснован структурой данных: тестовый набор практически сбалансирован (361 COVID / 359 Normal, отношение классов 1,006), поэтому метрика не смещена к мажоритарному классу и клинически интерпретируема как доля правильных решений скрининга.

4.2. Интервал Уилсона

Для доли событий 95 %-й доверительный интервал строится по формуле Уилсона:

$$CI_{\text{Wilson}} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}.$$

где:

- CI_{Wilson} — нижняя и верхняя границы доверительного интервала;
- $\hat{p}$ — выборочная доля (например, $\hat{p} = M(0)$);
- n — объём выборки, по которой оценивается доля;
- $z = z_{1-\alpha/2}$ — квантиль стандартного нормального распределения;
- $\alpha = 0{,}05$ — уровень значимости (95 % доверия), $z \approx 1{,}959964$.

4.3. Перцентильный бутстрэп

Для нелинейных вторичных метрик (F1) доверительный интервал строится перцентильным бутстрэпом: по B повторным выборкам с возвращением вычисляется эмпирическое распределение метрики и берутся его квантили:

$$\left[\hat{q}_{\alpha/2},\ \hat{q}_{1-\alpha/2}\right], \qquad \hat{q}_{\tau} = \inf\{t:\ \hat{F}_B(t) \geq \tau\}.$$

где:

- $B = 2000$ — число бутстрэп-повторностей;
- $\hat{F}_B(t)$ — эмпирическая функция распределения метрики по B повторностям;
- $\hat{q}_{\tau}$ — квантиль уровня τ;
- $\alpha = 0{,}05$ — уровень значимости.

5. Результаты базового этапа (Baseline M(0))

5.1. Матрица ошибок (Confusion Matrix)

Класс COVID считается положительным; элементы матрицы ошибок определяются как счётчики совместных событий:

$$TP = N(\hat{y} = 0,\ y = 0), \quad FN = N(\hat{y} = 1,\ y = 0), \quad FP = N(\hat{y} = 0,\ y = 1), \quad TN = N(\hat{y} = 1,\ y = 1).$$

где:

- $N(\cdot)$ — число объектов, удовлетворяющих условию;
- TP — истинно положительные (верно найденный COVID);
- FN — пропуски (COVID предсказан как Normal);
- FP — ложные тревоги (Normal предсказан как COVID);
- TN — истинно отрицательные (верно найденный Normal).

Таблица 6. Матрица ошибок на тестовой выборке (n = 720)

Истина / Прогноз	**COVID**	**Normal**
COVID	354 (TP)	7 (FN)
Normal	5 (FP)	354 (TN)

В таблице зелёным выделены корректные классификации (TP, TN), красным — критические ошибки пропуска (FN), оранжевым — ложные тревоги (FP).

5.2. Анализ метрик эффективности

5.2.1. Доля верных ответов (Accuracy / M(0))

Метрика отвечает на вопрос «какую долю снимков система классифицирует верно» и является основной метрикой цикла. На тестовой выборке она вычисляется непосредственно по матрице ошибок:

$$M(0) = \frac{TP + TN}{n} = \frac{354 + 354}{720} = 0{,}9833.$$

где:

- $M(0)$ — значение основной метрики для замороженной модели;
- $TP = 354, TN = 354$ — верные положительные и отрицательные решения;
- $n = 720$ — объём тестовой выборки.

Таблица 7. Доля верных ответов (Accuracy)

Показатель	**Значение**	**95 % ДИ**	**Метод ДИ**	**Ориентир (M(0))**
Accuracy, $M(0)$	0,9833 ★	[0,9711; 0,9904]	Уилсон	0,9833

Итог оценки. Значение M(0) = 0,9833 принимается в качестве точки отсчёта цикла: на неизменённом тестовом наборе из 720 снимков модель ошибается в 12 случаях (7 пропусков и 5 ложных тревог).

5.2.2. Чувствительность (Recall / Sensitivity / TPR)

Чувствительность показывает, какую долю реальных случаев COVID система обнаруживает; клинически это доля пациентов, которых модель не пропустила:

$$TPR = \frac{TP}{TP + FN}.$$

где:

- TPR — чувствительность (True Positive Rate);
- $TP = 354$ — верно найденные случаи COVID;
- $FN = 7$ — пропущенные случаи COVID.

Таблица 8. Чувствительность (Recall)

Показатель	Значение	95 % ДИ	Метод ДИ	Ориентир (M(0))
Recall (TPR)	0,9806	[0,9605; 0,9906]	Уилсон	0,9833

Итог оценки. Из 361 случая COVID модель пропускает 7 (≈1,94 %), что соответствует значению 0,9806; это единственная вторичная метрика, уступающая ориентиру $M(0)$.

5.2.3. Точность (Precision / PPV)

Точность показывает, какую долю среди снимков, помеченных системой как COVID, составляют истинные случаи; клинически это доля подтверждённых тревог:

$$PPV = \frac{TP}{TP + FP}.$$

где:

- PPV — точность (Positive Predictive Value);
- $TP = 354$ — верно найденные случаи COVID;
- $FP = 5$ — ложные тревоги.

Таблица 9. Точность (Precision)

Показатель	Значение	95 % ДИ	Метод ДИ	Ориентир (M(0))
Precision (PPV)	0,9861	[0,9678; 0,9940]	Уилсон	0,9833

Итог оценки. Из 359 снимков, помеченных как COVID, ложными оказываются 5 (≈1,39 %), что соответствует значению 0,9861 и превышает ориентир $M(0)$.

5.2.4. Специфичность (Specificity / TNR)

Специфичность показывает, какую долю здоровых снимков система верно относит к классу Normal; клинически это доля пациентов, которых модель не отправила на лишнее дообследование:

$$TNR = \frac{TN}{TN + FP}.$$

где:

- TNR — специфичность (True Negative Rate);

- $TN = 354$ — верно найденные здоровые снимки;
- $FP = 5$ — ложные тревоги.

Таблица 10. Специфичность (Specificity)

Показатель	**Значение**	**95 % ДИ**	**Метод ДИ**	**Ориентир (M(0))**
Specificity (TNR)	0,9861	[0,9678; 0,9940]	Уилсон	0,9833

Итог оценки. Значение 0,9861 численно совпадает с точностью, поскольку в данной матрице ошибок $TP = TN = 354$ и $TP + FP = TN + FP = 359$; это совпадение является свойством конкретной матрицы, а не тождеством метрик.

5.2.5. F1-мера

F1-мера — гармоническое среднее точности и чувствительности; она штрафует модель за дисбаланс между пропусками и ложными тревогами:

$$F_1 = \frac{2 \cdot PPV \cdot TPR}{PPV + TPR} = \frac{2\,TP}{2\,TP + FP + FN}.$$

где:

- F_1 — F1-мера по классу COVID;
- PPV — точность (Precision);
- TPR — чувствительность (Recall);
- $TP = 354$, $FP = 5$, $FN = 7$ — элементы матрицы ошибок.

Таблица 11. F1-мера

Показатель	**Значение**	**95 % ДИ**	**Метод ДИ**	**Ориентир (M(0))**
F_1 (COVID)	0,9833	[0,9727; 0,9918]	Bootstrap ($B = 2000$)	0,9833

Итог оценки. Значение F1 = 0,9833 численно совпадает с M(0), что отражает почти полную симметрию ошибок (7 пропусков против 5 ложных тревог) и подтверждает сбалансированность качества по классам.

5.3. Сводная таблица метрик

Таблица 12. Сводная таблица результатов по всем метрикам

Метрика	**Формула**	**Значение**	**95 % ДИ**	**Ориентир $M(0)$**	**Отклонение**	**Статус**
Accuracy, $M(0)$	$(TP + TN)/n$	**0,9833 ★**	[0,9711; 0,9904]	0,9833	0,0000	**базовая ★**
Recall (TPR)	$TP/(TP + FN)$	0,9806	[0,9605; 0,9906]	0,9833	−0,0027	ниже ориентира
Precision (PPV)	$TP/(TP + FP)$	**0,9861 ★**	[0,9678; 0,9940]	0,9833	+0,0028	выше ориентира
Specificity (TNR)	$TN/(TN + FP)$	**0,9861 ★**	[0,9678; 0,9940]	0,9833	+0,0028	выше ориентира
F_1 (COVID)	$2TP/(2TP + FP + FN)$	0,9833	[0,9727; 0,9918]	0,9833	0,0000	= ориентиру

★ *— опорные значения цикла:* $M(0)$ *задаёт точку отсчёта, а Precision и Specificity отмечают лучшие значения среди метрик; отклонение рассчитано относительно* $M(0) = 0{,}9833$.

Итоговое ранжирование метрик (от лучшей к худшей): Precision = Specificity (0,9861) > Accuracy = F_1 (0,9833) > Recall (0,9806). Наиболее чувствительной к ошибкам является чувствительность (Recall): именно она определяет долю пропущенных случаев COVID и потому остаётся главным объектом контроля на последующих этапах аудита.

6. Воспроизводимость и фиксация артефактов

Все семь групп параметров методики зафиксированы в файле reproducibility.json: (1) версия и источник данных; (2) схема разбиения 80/10/10 (seed 42) с распределением классов; (3) случайный seed 42 для всех генераторов с детерминированным режимом; (4) архитектура и инициализация; (5) гиперпараметры обучения (таблица 4); (6) версии ключевых библиотек; (7) основная метрика и способ её вычисления.

Таблица 13. Артефакты предварительного этапа

Артефакт	Назначение	Контрольная сумма
best_model.pth	замороженный чекпойнт (122 тензора; 44 789 835 Б)	SHA-256 0ba793cb…b504f0
training_history.json	журнал обучения (test_accuracy 0,98333)	—
split_indices.json	индексы разбиения 80/10/10 (seed 42)	—
metrics.json	зафиксированные метрики этапа	—
reproducibility.json	полный фиксатор параметров	—

Среда инференса (Windows, RTX 2050, PyTorch 2.9.1+cu130) отлична от среды обучения (Colab, Tesla T4, PyTorch 2.9.0+cu126), однако точное совпадение метрики демонстрирует переносимость пайплайна инференса.

7. План последующих этапов аудита

Таблица 14. План последующих этапов практического цикла

Этап	Содержание	Статус
ПР1	Качество набора данных: полнота, валидность, дубликаты, утечки train↔test, баланс, качество разметки, репрезентативность, аномалии	будет добавлено
ПР2	Устойчивость к естественным искажениям (шум, размытие, JPEG); кривые устойчивости и интегральная метрика R-AUC	будет добавлено
ПР3	Состязательная устойчивость в постановке белого ящика (FGSM, PGD); ASR и R-AUC_ε; контроль независимой сильной атакой	будет добавлено
ПР4	Приватность обучающей выборки (Membership Inference Attack): ROC-AUC, Attack Accuracy, TPR@FPR, генерализационный разрыв	будет добавлено

ВЫВОДЫ

- Сформулирована аналитическая задача бинарной классификации COVID-19 / Normal и контекст применения модели (вспомогательная triage-сортировка); формализованы пространства входов, отображение f_θ и решающее правило.
- Выбран и описан набор данных COVID-19 Radiography Database (v4); сформирован сбалансированный пул из 7200 снимков (3600 / 3600) и выполнено разбиение 80/10/10 с seed 42 (5760 / 720 / 720).

- Определены входная (RGB 224×224×3) и выходная (2 логита → softmax) модальности; зафиксирован единый пайплайн предобработки инференса.
- Выбрана архитектура ResNet18 в режиме transfer learning (ImageNet, обучаемые layer4 + fc, 11 177 538 параметров) и обучена baseline-модель (20 эпох, лучшая — 15-я, валидационная точность 0,9917).
- Определена основная метрика качества (Accuracy) с обоснованием выбора и формальным аппаратом доверительного оценивания (Wilson; перцентильный бутстрэп для F_1).
- Зафиксирован базовый результат: M(0) = 0,9833 с 95 % ДИ Уилсона [0,9711; 0,9904] на тестовой выборке из 720 снимков; матрица ошибок $TP = 354$, $FN = 7$, $FP = 5$, $TN = 354$.
- Вторичные метрики: Recall = 0,9806 [0,9605; 0,9906], Precision = 0,9861 [0,9678; 0,9940], Specificity = 0,9861 [0,9678; 0,9940], F1 = 0,9833 [0,9727; 0,9918]; лучшие значения — у Precision и Specificity, наиболее критичная — Recall.
- Модель сохранена (best_model.pth, 44 789 835 Б, SHA-256 0ba793cb…b504f0), а все параметры эксперимента зафиксированы в reproducibility.json; результат воспроизведён в другой среде выполнения.
- Зафиксированы ограничения этапа (отсутствие patient-level разбиения и стратификации, расхождение сред обучения и инференса), которые будут количественно исследованы в ПР1–ПР4; результаты последующих этапов в настоящий отчёт не входят.