МИНОБРНАУКИ РОССИИ
Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)
Кафедра ИС

отчет

по практической работе

по дисциплине «Безопасность искусственного интеллекта»

Тема: Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки: предварительный этап

Студенты гр. 1378 Панов А.Ю., Ханна М.Н., Семенов М.Д.
Преподаватель Новикова Е.С.

Санкт-Петербург
2026

ЗАДАНИЕ

Цель работы: приобретение навыков аудита доверенности систем искусственного интеллекта на примере медицинской системы диагностики COVID-19 по рентгенограммам грудной клетки; формирование воспроизводимой «точки отсчёта» (замороженная базовая модель и её метрика) для всего практического цикла.

Исходная постановка задачи: бинарная классификация фронтальной рентгенограммы грудной клетки по признаку COVID-19 — класс «COVID» (положительный) против класса «Normal» (здоровый); решение принимается по одному изображению, без использования метаданных пациента. Требуется выбрать и описать набор данных, определить входную и выходную модальности, сформировать обучающую, валидационную и тестовую выборки, выбрать архитектуру глубокой модели, обучить baseline-модель, определить основную метрику качества и зафиксировать все параметры вычислительного эксперимента для воспроизводимости.

Известные параметры:

Таблица 1. Исходные параметры предварительного этапа

Параметр	Значение
Аналитическая задача	бинарная классификация: COVID (положительный) / Normal
Набор данных	COVID-19 Radiography Database (v4)
Организованный пул	7200 снимков (3600 COVID / 3600 Normal)
Входная модальность	RGB-изображение 224×224×3
Выходная модальность	2 логита → вероятности классов
Разбиение	80/10/10, seed 42 → 5760 / 720 / 720
Архитектура	ResNet18 (ImageNet), обучаемые layer4 + fc
Число параметров	11 177 538
Оптимизатор	Adam, lr $1\cdot10^{-4}$, weight decay $1\cdot10^{-5}$
Эпохи / батч	20 / 32
Основная метрика	Accuracy, M(0)
Значение M(0)	0,9833; 95 % ДИ Уилсона [0,9711; 0,9904]
Артефакт модели	best_model.pth (44 789 835 Б)

Дата сдачи работы на проверку: 27.10.2026

1. Аналитическая задача и контекст применения модели

Предметная область — медицинская визуализация: автоматический анализ фронтальных рентгенограмм грудной клетки. Аналитическая задача — бинарная классификация снимка по признаку COVID-19: класс «COVID» (положительный) против класса «Normal» (здоровый). Решение принимается по одному изображению, без использования метаданных пациента или анамнеза. Задача выбрана как типичный представитель медицинского машинного обучения: у неё простая и клинически интерпретируемая структура ошибок, общедоступные данные и компактная бинарная постановка.

Контекст применения модели — вспомогательный инструмент сортировки (triage) при скрининге потока пациентов: модель помечает и ранжирует снимки, окончательное решение принимается клиницистом. Система не предназначена для автономной постановки диагноза. Пропуск случая (ложноотрицательное решение) задерживает лечение и способствует распространению инфекции, тогда как ложная тревога (ложноположительное решение) ведёт к необоснованной изоляции и лишнему дообследованию. Асимметрия последствий превращает качество модели в вопрос безопасности.

В качестве точки отсчёта цикла фиксируется базовая (baseline) модель и её метрика качества на неизменённом тестовом наборе. Во всех последующих практических работах модель используется без изменения параметров, что обеспечивает сопоставимость результатов.

2. Набор данных

Источник данных — открытый набор «COVID-19 Radiography Database» (версия v4), классы COVID и Normal. Полная версия v4 содержит 3616 снимков класса COVID и 10192 снимка класса Normal. Для бинарной задачи используется сбалансированная подвыборка: первые 3600 отсортированных файлов каждого класса копируются в плоскую ImageFolder-структуру, что снимает исходный дисбаланс и выравнивает классы.

Поскольку локальный доступ к API платформы недоступен, для воспроизведения использовано зеркало набора, у которого число файлов по каждому классу точно совпадает с версией v4; тождество состава подтверждено попарным подсчётом файлов. Лицензия набора, указанная на его странице, — «Data files © Original Authors»: файлы данных принадлежат

авторам набора, явная открытая лицензия для перераспространения не заявлена; файлы данных в артефакты цикла не включаются.

Таблица 2. Состав используемого набора данных

Класс	Снимков в версии v4	Использовано в цикле	Доля в пуле
COVID	3616	3600	50,0 %
Normal	10192	3600	50,0 %
Итого	13 808	7200	100 %

3. Входная и выходная модальности

Входная модальность — RGB-изображение размера 224×224×3. Исходный снимок является полутоновым (grayscale) и конвертируется в трёхканальный вид (три одинаковых канала), после чего приводится к размеру 224×224 билинейной интерполяцией. Такой вход совместим с архитектурой ResNet18, предобученной на трёхканальных изображениях ImageNet.

Пайплайн предобработки инференса: Resize((224, 224)) → ToTensor() → Normalize со средними (0,485; 0,456; 0,406) и стандартными отклонениями (0,229; 0,224; 0,225). Обучающий пайплайн дополняет эту цепочку аугментациями, применяемыми исключительно к обучающей выборке; валидационная и тестовая выборки обрабатываются тем же пайплайном, что и инференс.

Выходная модальность — вектор из двух логитов, преобразуемый в вероятности классов P(COVID) и P(Normal); итоговый ответ системы — класс с максимальной вероятностью. Тождество пайплайна инференса во всех артефактах цикла — обязательное условие сопоставимости результатов.

4. Обучающая, валидационная и тестовая выборки

Схема разбиения воспроизводит исходный ноутбук: классы сортируются по алфавиту (COVID = 0, Normal = 1), после чего применяется случайное разбиение с пропорциями 80/10/10 и фиксированным seed 42. Итоговые размеры: обучающая выборка — 5760 снимков, валидационная — 720, тестовая — 720. Seed зафиксирован для всех генераторов случайности с включением детерминированного режима, что делает разбиение воспроизводимым.

Таблица 3. Распределение классов по выборкам

Выборка	Всего	COVID	Normal	Доля
Обучающая	5760	2884	2876	80 %
Валидационная	720	355	365	10 %
Тестовая	720	361	359	10 %

Ограничения схемы: случайное разбиение не выполняет стратификацию по классам (баланс достигнут эмпирически), а метаданные набора не содержат идентификаторов пациентов, поэтому разбиение по субъектам непостроимо. Оба ограничения зафиксированы и будут количественно оценены на последующих этапах.

5. Архитектура и обучение baseline-модели

5.1. Архитектура

Архитектура — ResNet18 в режиме transfer learning: загружались предобученные веса ImageNet, все параметры замораживались, кроме блока layer4 (дообучение под медицинский домен) и новой классификационной головы Dropout(0,5) + Linear(512, 2). Общее число параметров — 11 177 538. Выбор архитектуры обоснован её распространённостью в медицинской визуализации, умеренным размером (совместимым с учебным вычислительным бюджетом) и наличием предобученных весов.

5.2. Гиперпараметры обучения

Таблица 4. Гиперпараметры обучения базовой модели

Параметр	Значение
Функция потерь	CrossEntropyLoss
Оптимизатор	Adam
Скорость обучения	$1 \cdot 10^{-4}$
Weight decay	$1 \cdot 10^{-5}$
Планировщик	ReduceLROnPlateau (по валидационной точности)
Число эпох	20 (лучшая эпоха — 15)
Размер батча	32
Ранняя остановка	patience 5
Аугментации (только train)	горизонтальное отражение, поворот 10°, яркость/контраст 0,2
Размер входа	224×224
Замораживание слоёв	все, кроме layer4 и головы fc

5.3. Процедура обучения

Обучение выполнено за 20 эпох; планировщик снижал скорость обучения по валидационной точности, ранняя остановка не сработала, чекпойнт сохранялся по лучшей валидационной точности (эпоха 15, значение 0,9917). Сохранённый чекпойнт — словарь состояния модели (122 тензора, 44 789 835 байт), загружаемый на CPU и восстанавливаемый заданной архитектурой.

5.4. Среда выполнения

Таблица 5. Среда выполнения эксперимента

Компонент	Обучение baseline	Воспроизведение
Платформа	Google Colab	Windows (локально)
Графический ускоритель	NVIDIA Tesla T4 (15,8 ГБ)	NVIDIA GeForce RTX 2050
Версия PyTorch	2.9.0+cu126	2.9.1+cu130
Дата	08.02.2026	—
Значение M(0)	0,98333 (журнал обучения)	0,9833 [0,9711; 0,9904]

6. Основная метрика качества решения задачи

6.1. Определение метрики

Основная метрика качества — Accuracy (доля верных предсказаний на тестовой выборке). Она отвечает на вопрос, какую долю снимков система классифицирует верно, и клинически интерпретируема как доля правильных решений скрининга. Выбор метрики обоснован структурой данных: тестовый набор практически сбалансирован (361 COVID / 359 Normal, отношение классов 1,006), поэтому Accuracy не смещена к мажоритарному классу.

Дополнительно вычисляются вторичные метрики по классу COVID: recall (доля найденных случаев), precision (доля подтверждённых тревог) и F1 (гармоническое среднее recall и precision). Для доли верных ответов и вторичных метрик приведены 95 %-е доверительные интервалы: для долей — методом Уилсона, для F1 — перцентильным бутстрэпом (2000 повторностей).

6.2. Результаты базового эксперимента

На неизменённом тестовом наборе (n = 720: 361 COVID / 359 Normal) замороженный чекпойнт показывает M(0) = 0,9833. Матрица ошибок приведена в таблице 6.

Таблица 6. Матрица ошибок на тестовой выборке (n = 720)

Истина / Прогноз	COVID	Normal
COVID	354 (TP)	7 (FN)
Normal	5 (FP)	354 (TN)

В таблице зелёным выделены корректные классификации (TP, TN), красным — критические ошибки пропуска (FN), оранжевым — ложные тревоги (FP).

Таблица 7. Метрики предварительного этапа

Метрика	Значение	95 % ДИ	Комментарий
Accuracy, M(0)	0,9833 ★	[0,9711; 0,9904]	основная метрика (опорная)
Recall (COVID)	0,9806	[0,9605; 0,9906]	пропущено 7 из 361
Precision (COVID)	0,9861	[0,9678; 0,9940]	5 ложных тревог из 359
F1 (COVID)	0,9833	[0,9727; 0,9918]	гармоническое среднее

Значение M(0) = 0,9833 принимается в качестве точки отсчёта цикла: на неизменённом тестовом наборе из 720 снимков модель ошибается в 12 случаях (7 пропусков и 5 ложных тревог). Наиболее критичной метрикой остаётся recall: именно она определяет долю пропущенных случаев COVID.

7. Сохранение модели и фиксация параметров эксперимента

7.1. Артефакты

Модель сохранена в виде словаря состояния PyTorch; для артефактов рассчитаны контрольные суммы, позволяющие независимо подтвердить тождество использованных файлов.

Таблица 8. Артефакты предварительного этапа

Артефакт	Назначение	Контрольная сумма
best_model.pth	замороженный чекпойнт (122 тензора; 44 789 835 Б)	SHA-256 0ba793cb…b504f0
training_history.json	журнал обучения (test_accuracy 0,98333)	—
split_indices.json	индексы разбиения 80/10/10 (seed 42)	—
metrics.json	зафиксированные метрики этапа	—

Артефакт	Назначение	Контрольная сумма
reproducibility.json	полный фиксатор параметров эксперимента	—

7.2. Воспроизводимость

Все семь групп параметров зафиксированы в файле reproducibility.json: версия и источник данных; схема разбиения 80/10/10 (seed 42) с распределением классов; случайный seed 42 для всех генераторов с детерминированным режимом; архитектура и инициализация; гиперпараметры обучения; версии ключевых библиотек; основная метрика и способ её вычисления.

Среда инференса (Windows, RTX 2050, PyTorch 2.9.1+cu130) отлична от среды обучения (Colab, Tesla T4, PyTorch 2.9.0+cu126), однако точное совпадение метрики демонстрирует переносимость пайплайна инференса.

ВЫВОДЫ

— Сформулирована аналитическая задача бинарной классификации COVID-19 / Normal и контекст применения модели (вспомогательная triage-сортировка).

— Выбран и описан набор данных COVID-19 Radiography Database (v4); сформирован сбалансированный пул из 7200 снимков (3600 / 3600).

— Определены входная (RGB 224×224×3) и выходная (два логита → вероятности) модальности; зафиксирован единый пайплайн предобработки инференса.

— Сформированы обучающая, валидационная и тестовая выборки в пропорции 80/10/10 с seed 42 (5760 / 720 / 720).

— Выбрана архитектура ResNet18 в режиме transfer learning (11 177 538 параметров) и обучена baseline-модель (20 эпох, лучшая — 15-я, валидационная точность 0,9917).

— Определена основная метрика качества (Accuracy); зафиксирован базовый результат M(0) = 0,9833 с 95 % ДИ [0,9711; 0,9904] и матрица ошибок TP = 354, FN = 7, FP = 5, TN = 354.

— Модель сохранена (best_model.pth, 44 789 835 Б, SHA-256 0ba793cb…b504f0), параметры эксперимента зафиксированы в reproducibility.json.

— Зафиксированы ограничения этапа (отсутствие разбиения по пациентам и стратификации, расхождение сред обучения и инференса), которые будут исследованы на следующих этапах.