МИНОБРНАУКИ РОССИИ
Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)
Кафедра ИС

отчет

по практической работе

по дисциплине «Безопасность искусственного интеллекта»

Тема: Аудит доверенности системы диагностики COVID-19 по рентгенограммам грудной клетки: предварительный этап

Студенты гр. 1378 Панов А.Ю., Ханна М.Н., Семенов М.Д.
Преподаватель Новикова Е.С.

Санкт-Петербург
2026

ЗАДАНИЕ

Цель работы: приобретение навыков аудита доверенности систем искусственного интеллекта на примере медицинской системы диагностики COVID-19 по рентгенограммам грудной клетки; формирование воспроизводимой «точки отсчёта» (замороженная базовая модель и её метрика) для всего практического цикла.

Исходная постановка задачи: бинарная классификация фронтальной рентгенограммы грудной клетки по признаку COVID-19 — класс «COVID» (положительный) против класса «Normal» (здоровый); решение принимается по одному изображению, без использования метаданных пациента. Требуется выбрать и описать набор данных, определить входную и выходную модальности, сформировать обучающую, валидационную и тестовую выборки, выбрать архитектуру глубокой модели, обучить baseline-модель, определить основную метрику качества и зафиксировать все параметры вычислительного эксперимента для воспроизводимости.

Известные параметры:

Таблица 1. Исходные параметры предварительного этапа

Параметр	Значение
Набор данных	COVID-19 Radiography Database (v4), классы COVID и Normal
Организованный пул	7200 снимков (3600 COVID / 3600 Normal)
Размер изображения	299×299 px (исходный PNG); вход модели — 224×224×3
Схема разбиения	80/10/10, seed 42 → 5760 / 720 / 720
Архитектура	ResNet18 (transfer learning, ImageNet), head: Dropout(0.5) + Linear(512, 2)
Основная метрика	Accuracy (доля верных решений)
Базовая метрика M(0)	0,9833; 95 % ДИ Уилсона [0,9711; 0,9904]

Дата сдачи работы на проверку: 27.10.2026

ТЕОРИЯ

Доверенность (trustworthiness) системы искусственного интеллекта — интегральная характеристика, складывающаяся из нескольких измеримых свойств: качества данных, устойчивости к естественным искажениям входов, состязательной устойчивости, приватности обучающей выборки и интерпретируемости решений. Оценка доверенности требует не одного числа, а согласованного набора измерений, выполненных на одном и том же объекте исследования. Настоящий практический цикл построен именно по такому принципу: единый набор данных и единая замороженная модель последовательно исследуются по каждому из свойств доверенности.

В качестве точки отсчёта цикла фиксируется базовая (baseline) модель и её метрика качества $M(0)$ на неизменённом тестовом наборе. Согласно завершающему правилу методических рекомендаций, базовая модель должна использоваться во всех практических работах без изменения её параметров: любое дообучение или замена весов сделали бы результаты несопоставимыми, поскольку измеряемые изменения свойств нельзя было бы отделить от изменения самой модели. Поэтому предварительный этап завершается замораживанием чекпойнта и полной фиксацией параметров эксперимента.

Предметная область — медицинская визуализация: автоматический анализ фронтальных рентгенограмм грудной клетки. Такие системы чувствительны к асимметрии последствий ошибок: пропуск случая (ложноотрицательное решение) задерживает лечение и способствует распространению инфекции, тогда как ложная тревога (ложноположительное решение) ведёт к необоснованной изоляции и лишнему дообследованию. Эта асимметрия превращает качество модели из чисто технической характеристики в вопрос безопасности, что и мотивирует последующий анализ устойчивости и приватности.

Формально решается задача бинарной классификации. Для тестовой выборки объёма n основная метрика $M(\theta)$ определяется как доля верных решений — совпадений прогноза модели с истинной меткой. Для доли событий доверительный интервал строится методом Уилсона, который корректно работает на границах и при умеренных объёмах выборки; для нелинейных вторичных метрик (F1) применяется percentile-bootstrap. Класс COVID считается положительным, поэтому матрица ошибок

интерпретируется через TP, FN, FP и TN, а вторичные метрики (recall, precision, F1) вычисляются по классу COVID.

Воспроизводимость эксперимента обеспечивается фиксацией семи групп параметров: версии и источника данных, схемы разбиения, случайного seed, архитектуры и инициализации, гиперпараметров обучения, версий библиотек и способа вычисления основной метрики. Дополнительно контролируются контрольные суммы артефактов, что позволяет независимо подтвердить тождество использованного чекпойнта.

ХОД РАБОТЫ

1. Постановка задачи

1.1. Предметная область и аналитическая задача

Предметная область — медицинская визуализация: автоматический анализ фронтальных рентгенограмм грудной клетки. Аналитическая задача — бинарная классификация снимка по признаку COVID-19: класс «COVID» (положительный) против класса «Normal» (здоровый). Решение принимается по одному изображению, без использования метаданных пациента или анамнеза. Задача выбрана как типичный представитель медицинского машинного обучения: у неё простая и клинически интерпретируемая структура ошибок, общедоступные данные и компактная бинарная постановка, удобная для систематического исследования свойств доверенности.

Контекст применения модели — вспомогательный инструмент сортировки (triage) при скрининге потока пациентов: модель помечает и ранжирует снимки, окончательное решение остаётся за клиницистом. Система не предназначена для автономной постановки диагноза. Класс COVID является целевым положительным классом; пропуск случая (ложный отрицательный, FN) ведёт к распространению инфекции и задержке лечения, а ложная тревога (ложный положительный, FP) — к необоснованной изоляции и лишнему дообследованию.

1.2. Формальная постановка и обозначения

Пусть D = {(x_i, y_i)}_{i=1..n} — тестовая выборка, где x_i — изображение размера 224×224×3, y_i ∈ {0, 1} — истинная метка (0 — COVID, 1 — Normal). Модель f_θ: R^{224×224×3} → R^2 выдаёт вектор логитов, из которого прогноз определяется как yhat_i = argmax f_θ(x_i). Основная метрика:

$$M(\theta) = (1/n) \cdot \Sigma_i \, 1[\hat{y}_i = y_i].$$

Класс COVID считается положительным, поэтому элементы матрицы ошибок обозначаются TP (истинно положительные), FN (пропуски), FP (ложные тревоги) и TN (истинно отрицательные). Доверительный интервал для M(θ) как доли событий строится методом Уилсона с уровнем доверия 95 %; интервалы для вторичных метрик — percentile-bootstrap с B = 2000 повторностей.

2. Набор данных и модальности

2.1. Источник и состав

Источник данных — открытый набор «COVID-19 Radiography Database» (версия v4), классы COVID и Normal. Полная версия v4 содержит 3616 снимков класса COVID и 10192 снимка класса Normal. Для бинарной задачи курса используется сбалансированная подвыборка: первые 3600 отсортированных файлов каждого класса копируются в плоскую ImageFolder-структуру, что снимает исходный дисбаланс и выравнивает классы. Поскольку локальный доступ к API платформы недоступен, для воспроизведения использовано зеркало набора, у которого число файлов по каждому классу точно совпадает с версией v4; тождество состава подтверждено попарным подсчётом файлов.

Таблица 2. Состав используемого набора данных

Класс	Снимков в версии v4	Использовано в цикле
COVID	3616	3600
Normal	10192	3600
Итого	13808	7200

Лицензия набора, указанная на его странице, — «Data files © Original Authors»: файлы данных принадлежат авторам набора, явная открытая лицензия для перераспространения не заявлена; файлы данных в артефакты цикла не включаются.

2.2. Входная и выходная модальности

Входная модальность — RGB-изображение размера 224×224×3. Исходный снимок является полутоновым (grayscale) и конвертируется в трёхканальный вид (три одинаковых канала), после чего приводится к размеру 224×224 билинейной интерполяцией. Такой вход совместим с архитектурой ResNet18, предобученной на трёхканальных изображениях ImageNet.

Пайплайн предобработки инференса: Resize((224, 224)) → ToTensor() → Normalize(mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225]). Обучающий пайплайн дополняет эту цепочку аугментациями, применяемыми исключительно к обучающей выборке; валидационная и тестовая выборки обрабатываются тем же пайплайном, что и инференс. Выходная модальность — вектор логитов размерности 2, преобразуемый функцией softmax в вероятности P(COVID) и P(Normal); итоговый ответ — класс с максимальной

вероятностью. Тождество пайплайна инференса во всех артефактах цикла — обязательное условие сопоставимости результатов.

2.3. Схема разбиения train / validation / test

Схема разбиения воспроизводит исходный ноутбук: классы сортируются по алфавиту (COVID = 0, Normal = 1), после чего применяется случайное разбиение с пропорциями 80/10/10 и фиксированным seed 42. Итоговые размеры: обучающая выборка — 5760 снимков, валидационная — 720, тестовая — 720. Seed зафиксирован для всех генераторов случайности (random, numpy, torch, CUDA) с включением детерминированного режима, что делает разбиение воспроизводимым.

Таблица 3. Распределение классов по выборкам

Выборка	Всего	COVID	Normal	Доля
Обучающая	5760	2884	2876	80 %
Валидационная	720	355	365	10 %
Тестовая	720	361	359	10 %

Ограничения схемы. Во-первых, случайное разбиение не выполняет стратификацию по классам: баланс достигнут эмпирически, а не гарантирован процедурой; фиксация seed устраняет неоднозначность для данного цикла. Во-вторых, метаданные набора не содержат идентификаторов пациентов, поэтому разбиение по субъектам (предотвращающее утечку между выборками) непостроимо; это ограничение зафиксировано и будет количественно оценено на последующих этапах через анализ дубликатов и межвыборочных совпадений.

2.4. Предобработка и аугментации

Аугментации применяются только к обучающей выборке: RandomHorizontalFlip(p = 0.5), RandomRotation(10°) и ColorJitter(brightness = 0.2, contrast = 0.2) после приведения к размеру 224×224. Валидационная и тестовая выборки не аугментируются — это обеспечивает корректность измерения метрики и её сопоставимость между этапами цикла.

3. Архитектура и обучение базовой модели

3.1. Архитектура и гиперпараметры

Архитектура — ResNet18 в режиме transfer learning: загружались предобученные веса ImageNet, все параметры замораживались, кроме блока layer4 (дообучение под медицинский домен) и новой классификационной головы fc = Sequential(Dropout(p = 0.5), Linear(512, 2)). Общее число параметров — 11 177 538. Выбор архитектуры обоснован её распространённостью в медицинской визуализации, умеренным размером (совместимым с учебным вычислительным бюджетом) и наличием предобученных весов.

Таблица 4. Гиперпараметры обучения базовой модели

Параметр	**Значение**
Оптимизатор	Adam
Скорость обучения	1e-4
Weight decay	1e-5
Планировщик	ReduceLROnPlateau(mode='max', factor=0.5, patience=3, min_lr=1e-7)
Функция потерь	CrossEntropyLoss
Число эпох	20 (лучшая эпоха — 15)
Размер батча	32
Ранняя остановка	patience 5
Аугментации (только train)	RandomHorizontalFlip(0.5), RandomRotation(10°), ColorJitter(0.2; 0.2)
Размер входа	224×224
Замораживание слоёв	все, кроме layer4 и головы fc
Число параметров	11 177 538

3.2. Процедура обучения

Обучение выполнено за 20 эпох; планировщик снижал скорость обучения по валидационной точности, ранняя остановка не сработала, чекпойнт сохранялся по лучшей валидационной точности (эпоха 15, значение 0,9917). Сохранённый чекпойнт — это словарь состояния модели (122 тензора, около 44,8 МБ), который загружается на CPU и восстанавливается заданной архитектурой. В соответствии с завершающим правилом методики базовая модель заморожена: на всех последующих этапах она используется без изменения параметров.

3.3. Среда выполнения

Таблица 5. Среда выполнения эксперимента

Компонент	Обучение baseline	Воспроизведение
Платформа	Google Colab	Windows (локально)
Графический ускоритель	NVIDIA Tesla T4 (15,8 ГБ)	NVIDIA GeForce RTX 2050
Версия PyTorch	2.9.0+cu126	2.9.1+cu130
Дата	08.02.2026	—
Значение M(0)	0,98333 (история обучения)	0,9833 [0,9711; 0,9904]

4. Основная метрика качества и её обоснование

Основная метрика качества — Accuracy (доля верных предсказаний на тестовой выборке). Согласно методическим рекомендациям, для задач классификации допустимыми основными метриками являются Accuracy, Balanced Accuracy, Macro-F1 и ROC-AUC. Выбор Accuracy обоснован структурой данных: тестовый набор практически сбалансирован (361 COVID / 359 Normal, отношение классов 1,006), поэтому Accuracy не смещена к мажоритарному классу и клинически интерпретируема как доля правильных решений скрининга.

Способ вычисления: для каждого объекта тестовой выборки сравниваются argmax логитов модели и истинная метка; класс COVID считается положительным. Наряду с основной метрикой для полноты вычисляются вторичные метрики по классу COVID (recall, precision, F1); они приводятся с доверительными интервалами. Accuracy зафиксирована как основная метрика для всего цикла: на этапе устойчивости она вычисляется на искажённых данных, на этапе состязательной устойчивости — как устойчивая точность, на этапе приватности — как основа генерализационного разрыва. Тем самым результаты всех этапов сопоставимы между собой и с точкой отсчёта M(0).

5. Зафиксированный результат предварительного этапа

5.1. Матрица ошибок

На неизменённом тестовом наборе (n = 720: 361 COVID / 359 Normal) замороженный чекпойнт показывает M(0) = 0,9833. Матрица ошибок приведена в таблице 6.

Таблица 6. Матрица ошибок на тестовой выборке (n = 720)

Истина \ Прогноз	COVID	Normal
COVID	354 (TP)	7 (FN)
Normal	5 (FP)	354 (TN)

5.2. Основная и вторичные метрики

Основная метрика M(0) = 0,9833 с 95 %-м доверительным интервалом Уилсона [0,9711; 0,9904]. Ширина интервала отражает объём тестовой выборки (720 снимков). Результат совпадает с фиксацией исходного обучения (test_accuracy = 0,98333) и воспроизведён на другом оборудовании, что подтверждает корректность пайплайна предобработки и разбиения.

Таблица 7. Метрики предварительного этапа с 95 %-ми доверительными интервалами

Метрика	Значение	95 % ДИ	Метод
Accuracy (основная)	0,9833	[0,9711; 0,9904]	Уилсон
Recall (COVID)	0,9806	[0,9605; 0,9906]	Уилсон
Precision (COVID)	0,9861	[0,9678; 0,9940]	Уилсон
F1 (COVID)	0,9833	[0,9727; 0,9918]	Bootstrap (B = 2000)

5.3. Артефакты и контрольные суммы

Таблица 8. Артефакты предварительного этапа

Артефакт	Назначение	Контрольная сумма
best_model.pth	замороженный чекпойнт (122 тензора, 44 789 835 Б)	SHA-256 0ba793cb…b504f0
training_history.json	история обучения (test_accuracy = 0,98333)	—
split_indices.json	индексы разбиения 80/10/10 (seed 42)	—
metrics.json	зафиксированные метрики этапа	—
reproducibility.json	полный фиксатор параметров эксперимента	—

6. Воспроизводимость

Все семь групп параметров методики зафиксированы в файле reproducibility.json: (1) версия и источник данных; (2) схема разбиения 80/10/10 (seed 42) с распределением классов по выборкам; (3) случайный seed 42 для всех генераторов с детерминированным режимом; (4) архитектура и инициализация (ResNet18, transfer learning, заморожены все слои, кроме layer4 и головы); (5) гиперпараметры обучения (таблица 4); (6) версии ключевых

библиотек; (7) основная метрика и способ её вычисления с описанием процедуры интервала.

Файлы воспроизводимости: reproducibility.json (полный фиксатор параметров), requirements.txt (зависимости), скрипт точного воспроизведения M(0) на замороженном чекпойнте, а также ячейка проверки, сверяющая печатаемое значение M(0) с фиксатором. Среда инференса (Windows, RTX 2050, CUDA) отлична от среды обучения (Colab, Tesla T4), однако точное совпадение метрики демонстрирует переносимость пайплайна инференса.

7. План последующих этапов

В соответствии с методикой замороженный чекпойнт и метрика M(0) = 0,9833 [0,9711; 0,9904] будут использоваться без изменений на всех последующих этапах цикла. Настоящий отчёт содержит исключительно предварительный этап; результаты, таблицы и выводы последующих работ будут добавлены в отчёт по мере их выполнения (таблица 9).

Таблица 9. План последующих этапов практического цикла

Этап	Содержание	Статус
ПР1	Качество набора данных: полнота, валидность, дубликаты, утечки train↔test, баланс, качество разметки, репрезентативность, аномалии	будет добавлено
ПР2	Устойчивость к естественным искажениям (шум, размытие, JPEG); кривые устойчивости и интегральная метрика R-AUC	будет добавлено
ПР3	Состязательная устойчивость в постановке белого ящика (FGSM, PGD); ASR и R-AUC_ε; контроль независимой сильной атакой	будет добавлено
ПР4	Приватность обучающей выборки (Membership Inference Attack): ROC-AUC, Attack Accuracy, TPR@FPR, генерализационный разрыв	будет добавлено

ВЫВОДЫ

В ходе предварительного этапа сформулирована аналитическая задача и контекст применения модели, выбран и описан набор данных, определены входная и выходная модальности, сформированы обучающая, валидационная и тестовая выборки, выбрана архитектура глубокой модели, обучена базовая модель, определена основная метрика качества и зафиксированы все параметры вычислительного эксперимента.

Обученная базовая модель (ResNet18, transfer learning) достигла значения основной метрики M(0) = 0,9833 с 95 %-м доверительным интервалом Уилсона [0,9711; 0,9904] на неизменённом тестовом наборе из 720 снимков (TP = 354, FN = 7, FP = 5, TN = 354). Результат в точности воспроизводится из сохранённого чекпойнта и совпадает с фиксацией истории обучения.

Сформирована воспроизводимая «точка отсчёта» практического цикла: замороженный чекпойнт, зафиксированная метрика с доверительным интервалом и полный набор параметров эксперимента. В соответствии с завершающим правилом методики базовая модель будет использоваться во всех последующих работах без изменения параметров, что обеспечивает сопоставимость измерений доверенных свойств.

Зафиксированы ограничения этапа: невозможность разбиения по субъектам из-за отсутствия идентификаторов пациентов, отсутствие стратификации при разбиении и расхождение сред обучения и воспроизведения. Эти ограничения будут количественно исследованы на последующих этапах цикла. Результаты последующих работ в настоящий отчёт не входят и будут представлены отдельно.